


4주차 진도보고서

AI 기반 유사 문서 검출 시스템






INDEX

목차

목차1	완료한 일
목차2	진행 중인 일
목차3	앞으로 할 일




수정된 WBS

WBS 및 간트차트				3주차							4주차							5주차						
				15	16	17	18	19	20	21	22	23	24	25	26	27	28	29	30	1	2	3	4	5
구분	역할분류	작업	완료여부	월	화	수	목	금	토	일	월	화	수	목	금	토	일	월	화	수	목	금	토	일
기획/정책/운영	공통 ▼	주제 선택	완료 ▼																					추석연
	한동균 ▼	수행계획서 작성	완료 ▼																					
	유예지 ▼	WBS 및 간트차트 작성	완료 ▼																					
	공통 ▼	범위·성과지표 정의	완료 ▼																					
	유예지 ▼	모델/도구 선정 기준서	완료 ▼																					
	한동균 ▼	민감도 정책표	완료 ▼																					
	한동균 ▼	단위·숫자 규칙 사전	완료 ▼																					
	유예지 ▼	보안·프라이버시 가이드	완료 ▼																					
	유예지 ▼	협업 컨벤션	완료 ▼																					
	한동균 ▼	위험/이슈 레지스터	완료 ▼																					
	공통 ▼	운영 기준선 문서화	작업대기 ▼																					
데이터/코퍼스/파싱	공통 ▼	템플릿 정의	완료 ▼																					
	공통 ▼	코퍼스 작성 v1	기능구현중 ▼																					
	공통 ▼	코퍼스 확장 v2	기능구현중 ▼																					
	공통 ▼	섹션 라벨링	작업대기 ▼																					
	공통 ▼	문서 파서 구현	기능구현중 ▼																					
	공통 ▼	OCR 전처리	작업대기 ▼																					
	공통 ▼	OCR 엔진 파이프라인	작업대기 ▼																					
	공통 ▼	숫자/단위 정규화	작업대기 ▼																					
	공통 ▼	표/차트 처리	작업대기 ▼																					
	공통 ▼	레이아웃 좌표 매핑	작업대기 ▼																					
	공통 ▼	파서/OCR 테스트	작업대기 ▼																					
	임베딩/벡터스코어/검색(1차점수)	공통 ▼	Chunking 정책	작업대기 ▼																				
공통 ▼		메타데이터 설계	작업대기 ▼																					
공통 ▼		임베딩 파이프라인	작업대기 ▼																					
공통 ▼		벡터스코어 구축	작업대기 ▼																					
공통 ▼		초기 인덱싱	작업대기 ▼																					



목차 1 완료한 일





완료한 일



기획/정책/운영

융합보안 프리캡스톤 디자... / 기획/정책/운영

9월 19일 편집 예

AI로 질문하고 조사하고 생성하세요
⌘ + Alt + J

기획/정책/운영

범위/성과 지표 정의

모델/도구 선정 기준서

- 성과 지표:
 - 탐지율(놓침 방지)
 - 정밀도(오탐 억제)
 - 평균 처리시간(실사용성)
 - 숫자 유출 인식률
 - 근거 제공률(하이라이트/설명 가능성)
 - DLP 대비 차별점
- 성과 목표:
 - 중간 목표: 탐지율 80%, 정밀도 75%, 평균 처리시간 1.5초/페이지
 - 최종 목표: 탐지율 90%, 정밀도 85%, 평균 처리시간 1.0초/페이지

문서 파싱·OCR

임베딩(의미 벡터)

벡터 스토어/검색

리랭커(선택: Top-K 정밀 재정렬)

(옵션) PII/민감정보 보조 탐지

결론..?

범위/성과 지표 정의

범위/성과 지표 정의

- 성과 지표:

- 탐지율(놓침 방지)
- 정밀도(오탐 억제)
- 평균 처리시간(실사용성)
- 숫자 유출 인식률
- 근거 제공률(하이라이트/설명 가능성)
- DLP 대비 차별점

- 성과 목표:

- **중간 목표:** 탐지율 80%, 정밀도 75%, 평균 처리시간 1.5초/페이지
- **최종 목표:** 탐지율 90%, 정밀도 85%, 평균 처리시간 1.0초/페이지

모델/도구 선정 기준서

모델/도구 선정 기준서

- 문서 파싱·OCR
- 임베딩(의미 벡터)
- 벡터 스토어/검색
- 리랭커(선택: Top-K 정밀 재정렬)
- (옵션) PII/민감정보 보조 탐지
- 결론..?

문서 파싱·OCR

카테고리	도구	장점	단점/주의	언제 쓰나	설치·사용법(요약)
HWP/HWPX	Hancom HWP SDK	HWP/HWPX 직접 파싱, ~1,000개 함수 상용 지원. 안정적. (Hancom)	유료/계약 필요	HWP를 정확히 제어·대량 처리	문의/다운로드: 한컴 개발자 페이지 → SDK 안내. (Hancom)
HWP(오픈)	pyhwp	HWP v5 파서, ODT/텍스트 변환 (실험적). POC용 가벼움. (GitHub)	포맷/본문 복잡도에 제약	간단 텍스트 추출, 오픈소스 선호	<code>pip install --pre pyhwp</code> (실험 버전) (PyPI)
DOCX	python-docx	표·단락 등 개체 접근 쉬움, 생태계 활발. (python-docx.readthedocs.io)	스타일/이미지 세부 제어는 한계	슬라이싱(표 셀 단위)·본문 추출	<code>pip install python-docx</code> (PyPI)
PPTX	python-pptx	슬라이드·도형·텍스트 읽기/수정. 인덱싱 텍스트 추출에 적합. (python-pptx.readthedocs.io)	차트/복잡 레이아웃 처리 일부 수작업	발표자료의 슬라이드·노트 텍스트	
PDF(텍스트)	pdfminer.six	글자 좌표/폰트 등 정밀 텍스트 분석 강점. (pdfminer.six.readthedocs.io)	표/레이아웃은 직접 처리 필요	좌표 기반 하이라이트·근거 제시	
PDF(표/혼합)	PyMuPDF	빠른 추출 + <code>page.find_tables()</code> 로 표 추출	스캔 품질·비정형 표는 튜닝 필요	보고서 표/캡션 동시 추출	

결론..?

A. 전부 무료(온프레임) 시작

- HWP: pyhwp (안 되면 HWP → PDF → PaddleOCR)
- DOCX/PPTX: python-docx / python-pptx
- PDF: PyMuPDF
- 임베딩: BGE-M3
- 벡터DB: Qdrant(또는 pgvector)
- (선택) 리랭커: BGE Reranker



민감도 정책표

섹션 민감도(예측/목표가/내부지표) 가중치 테이블

해당 가중치 테이블은 프로젝트 진행과정에서 계속해서 변동이 있을 수 있음

가중치	분류	키워드 예시	선정 기준 및 근거
10(매우민감)	핵심 예측 데이터	목표주가, 적정주가, 예상매출액, 영업이익 전망, 순이익률 전망, 실적 예상치, 성장률 목표	목표주가는 투자자들이 가장 민감하게 반응하는 정보임. 공시되기 전 유출될 경우 자본시장법상 불공정거래에 해당 가능
8(고민감)	내부 평가 및 지표	내부등급, 투자 의견, 자체평가, 내부지표, 밸류에이션, 현금 흐름 전망, DCF 분석, RIM	외부 투자자들이 알 수 없는 회사 내부의 고유 분석 및 노하우와 판단 기준을 담고 있음
6(민감)	미공개 일정 및 계획	내부회의록, 경영진면담, 미팅내용, 신규사업계획, 출시예정일, 내부마감	CJ ENM 주가조작 사건과 같이 방송 프로그램 편성의 정보가 사전에 유출되어 주가가 급등락하는 사례처럼 주가에 영향을 줄 수 있는 내부 정보임
4(보통)	정량적 데이터	매출, 영업이익, 순이익, PER, PBR, ROA, ROE	대부분 공시 의무가 있는 정보임. 외부에서 상당히 접근 가능한 데이터일 가능성 높음
2(일반)	일반적 문구	시장 동향, 산업 분석, 배경, 결론, 요약, 주요리스크	이미 공개된 자료를 기반으로 작성된 경우가 대부분임



단위/숫자 규칙 사전

1. 단위 통일

- 정규식: `(\d+\.\d*)\s*(천|만|억|조)`
- 용도: 10억, 2.5조과 같이 한글 단위가 포함된 숫자를 식별

2. 화폐 및 통화 규격 통일

- 정규식: `([₩\,$¥])\d{1,3}(\d{3})/\d+\s(원|달러|엔)?`
- 용도: \$100, 10,000원, 2000엔 등 다양한 통화 표현을 식별

3. 백분율 및 bp

- 정규식: `(\d+\.\d*)\s*(%|bp)`
- 용도: 15%, 150bp와 같이 백분율과 bp를 식별

4. 날짜 및 기간

- 정규식: `(\d{4})년\s*(\d{1,2})월\s*(\d{1,2})일|\d{4}-\d{2}-\d{2}`
- 용도: 2024년 9월 18일, 2024-09-18과 같은 날짜 형식을 식별

정규식 사용 후 결과 예시

입력 텍스트	그룹 1	그룹 2
10억	10	억
2.5조	2.5	조

해당 코드들은 개발 시 필요한 형태로 수정하여 사용 가능



보안/프라이버시 가이드

가이드

1) 뭘 보호할지

- D1: 원문 기밀 – 내부 투자 보고서 원문/표/숫자.
- D2: 파생 데이터 – 청크 텍스트, 임베딩(벡터), 스니펫.
- D3: 사용자 업로드 – 외부 문서(검사 대상).
- D4: 개인정보(PII) 가능 – 이름/이메일/전화 등(문서 속에 섞여 있을 수 있음).

→ 로그에는 D1/D4 금지.

2) 데이터 흐름

1. 업로드 → 2) 파싱/OCR → 3) 청킹(문단/표셀) → 4) 임베딩 생성 → 5) 벡터DB에서 Top-K 후보(코사인) → 6) LLM 판정(PII 마스킹 후) → 7) 차단/경고/통과 기록(로그)

| 중요 포인트: LLM 호출 전에는 PII/민감정보 마스킹을 적용하고, 원문 전문은 기본적으로 저장하지 않음.

→ 원문 전문을 최대한 저장 안하고 진행하는게 포인트

3) 접근 통제

- 역할 4개
 - Admin: 키/설정.
 - Curator: 내부 코퍼스 관리(D1 접근 요청 가능).
 - Reviewer: 차단/경고 검토(원문 전문 기본 차단).
 - Uploader: 업로드만.
- 원문 열람: 기본 차단, 2인 승인(Admin+Curator) 시에만 열람.
- 계정 보안: 관리자 계정은 MFA 필수(OTP 앱). 비밀번호/암호는 패스워드 매니저에 보관.



협업 컨벤션

✓ 코드 컨벤션

“ 문자열을 처리할 때는 쌍따옴표를 사용하도록 합니다.

؛ 문장이 종료될 때는 세미콜론을 붙여줍니다.

🐪 함수명, 변수명은 카멜케이스로 작성합니다.

→ 카멜케이스 : 여러 단어를 붙여 쓸 때, 첫 단어만 소문자로 쓰고 이후 단어의 첫 글자만 대문자로 올려 쓰는 표기법

ex)

userName

maxScore

getUserData

uploadFilePath

- 공백·언더스코어 없이 단어를 붙여 쓰기
- 첫 단어는 소문자, 다음 단어들의 첫 글자만 대문자
- 숫자는 중간에 가능하지만 맨 앞 숫자 시작은 피하기

👉 가독성을 위해 한 줄에 하나의 문장만 작성합니다.



위험/이슈 레지스터

성능·오탐·비용·법무 리스크 식별/완화책

1. 성능 리크스

리스크	상세 내용	영향	발생 가능성	완화 방안
탐지 성능 미흡	유사 문구·숫자 검출 성능이 기대치 미달 (탐지율 80% 미만)	기밀 유출 탐지 실패 → 보안사고 발생	중	- 학습 데이터셋 확대 (다양한 투자 보고서 반영) - 숫자/단위 전처리 강화- ROC 분석 기반 임계치 최적화
처리 속도 저하	대용량 문서 업로드 시 분석 지연 (목표: 1.5초/페이지 초과)	실사용 어려움	중	- Chunking 최적화 - 경량 LLM 판사모듈 적용
수치·그래프 누락	OCR/레이아웃 파서에 서 표·차트의 숫자 일부 누락	숫자 기반 기밀 유출 탐지 불가	중~고	- OCR 전처리 강화 - 레이아웃 직표 매핑 개선 - 숫자 정규화 규칙 추가

2. 오탐 리스크

리스크	상세 내용	영향	발생 가능성	완화 방안
과도한 차단	정상적인 외부 보고서 까지 기밀 문서 유사 판정	현업 불편, 시스템 신뢰도 하락	중~고	- 민감도 가중 규칙 적용 (수치/특정 문장 비중 강화) - 판사 프롬프트 튜닝 - 관리자 Override 기능 제공
문맥 해석 오류	LLM이 맥락을 잘못 이해해 유사도 높게 판정	오탐 증가 → 비효율적 대응	중	- 다단계 판별 (벡터 검색 → LLM 판별 → 숫자 비교) - 근거 하이라이트 제시 → 사용자 검증 가능



템플릿 생성-hwp

00투자 보고서

Confidential - For Internal Use Only

2025. MM. DD

담당자	소속	HS 투자 회사	TEL	043-201-2039
	담당자	김 현 우	Email	wonseop82@korea.kr



HS Capital
Investment

목 차

I. 전체 요약 (Executive Summary)	1
1. 투자 대상 개요	1
2. 투자 목적 및 배경	1
3. 핵심 투자 포인트	1
4. 주요 리스크 요약	2
5. 최종 권고	2
II. 투자 개요 (Investment Overview)	3
1. 대상 기업 개요	3
2. 투자 구조 및 조건	4
3. 예상 Exit 시나리오	5
4. 거래 일정 (Timeline)	5
III. 회사 개요 (Company Overview)	24
1. 기업 연혁 및 성장 과정	24
2. 주요 경영진 및 지배구조	24
3. 비즈니스 모델 및 수익 구조	25
4. 주요 제품/서비스	25
IV. 시장 및 산업 분석 (Market & Industry Analysis)	34
1. 시장 규모 (TAM/SAM/SOM)	34
2. 성장 전망 및 동향	34
3. 경쟁 구도 (주요 경쟁사 비교)	37
4. 규제 및 정책 리스크	37

I 전체 요약

1 투자 대상 개요

- 기업명 : 000 주식회사 (법인등록번호: 000000000000000000)
- 대표자 : 000
- 주요 사업장 : 00시 00구 00로 123 (임차 여부/임대차 조건 기재)
- 주주 구성 :
 - 최대주주 000 (지분율 XX%, 특수관계 00와 공동 경영)
 - 주요 재무적 투자자: 00캐피탈(XX%), 00벤처스(XX%)
- 사업 규모 : 매출 00억원, 영업이익 00억원, 직원 수 00명
- 주요 고객사/계약처 : 삼성전자, 현대자동차, 00관공서 등 (상세 계약 조건 포함)
- 잠재 리스크 : 특정 매출처(매출의 XX%) 의존도, 최근 세무 조사 이슈

2 투자 목적 및 배경

- 전략적 목적 :
 - 당사 포트폴리오 기업 A사와 기술/유통망 시너지 창출
 - 해당 산업 내 시장 점유율 확대, 경쟁사 선제 차단
- 재무적 목적 :
 - 0년 내 IPO/M&A Exit 목표 (희망 밸류에이션: 00억원)
 - 현금흐름 확보 및 단기 차익 실현 가능성
- 정책/외부 환경 :
 - 정부의 00산업 지원 정책 (보조금/세제 혜택 규모)
 - 경쟁사 B사의 공격적 증설에 따른 대응 필요성

20XX년 ~ 20XX년 CAGR 0% → 20XX년 예상 시장 규모 0조원
(그래프: 연도별 시장 성장 추세선 그래프)

- 특정 세부 분야는 정부 지원 없이 자생적 성장이 어려워, 정책 변화에 크게 좌우됨
- 내부적으로는 00부처와의 협의 결과, 특정 산업군 예산 반영 가능성 확인 (아직 미공개 단계)

3 경쟁 구도 (주요 경쟁사 비교)

- 주요 경쟁사 현황
 - 경쟁사 A: 매출 00억원, 시장 점유율 0% (주요 고객사: 00社, 00기관)
 - 경쟁사 B: 공격적 가격 정책, 최근 00社와 전략적 제휴 체결
 - 경쟁사 C: 글로벌 진출 성공, 다만 국내 규제 리스크 존재

구분	경쟁사 A	경쟁사 B	경쟁사 C	대상 기업
매출				
시장 점유율				
주요 고객사				
핵심 기술				
주요 리스크				

- 투자 대상 기업의 상대적 위치 : 기술력 상위(특허 수, 전문 인력) 있으나 자본력 열위
- 비공식 정보에 따르면 경쟁사 B는 차기 펀딩 협상 결렬 가능성이 있어 단기적 투자 기회 발생 예상

템플릿 생성-docx

↓

←

[기업명] 투자 분석 보고서

Confidential document

작성일: 2000.00.00

작성자: 애널리스트 김현우

Email: wonseop82@korea.kr

 HS Capital Investment

서울특별시 성북구 삼선로00길 000

목차

- I. 기업 개요 및 투자 요약.....1
- 1. 기업 개요.....2
- 2. 경영진 및 지배 구조.....3
- 3. 투자 포인트 요약.....4
- II. 사업 및 재무 분석.....5
- 1. 핵심 사업 분석.....6
- 2. 재무 성과 및 추이.....7
- 3. 비용 구조 및 수익성.....8
- III. 산업 및 시장 동향.....9
- 1. 시장 규모.....10
- 2. 산업 성장성 분석.....10
- 3. 경쟁 환경 분석.....11

I 기업 개요 및 투자요약

1 기업 개요

- 기업명: [기업명] 주식회사
- 대표자: [대표자명]
- 주요 사업장: [주소]
- 주요 사업: (핵심 사업명)
- 주요 고객사/계약처: (고객사명), (고객사명), (고객사명) 등
- 주주 구성
 - 최대주주: [최대주주명] (지분을 XX%)
 - 주요 재무적 투자자: (재무적 투자자명)(XX%)
- 사업 규모
 - 매출: (금액)억 원
 - 영업이익: (금액)억 원
 - 직원 수: (인원)명

2 경영진 및 지배 구조

- 이사회 구성
 - CEO(창업주):기업 경영 전반을 총괄.

- 성장 동력
 - [신규 시장 진출, 신기술 도입 등]을 통해 향후 [사업 부문명]의 성장세를 더욱 가속화할 전망.

2 재무 성과 및 추이

[기업명]은 최근 [기간]간 지속적인 매출 성장을 기록하며 재무 건전성을 확보.

- 매출 및 영업이익 추이
 - 지난 3년간 연평균 [성장률]%이상의 성장률을 기록하며 재무 건전성을 확보. 특히 [연도]에는 영업이익이 전년 대비 [성장률]%급증.

구분	2022년	2023년	2024년
매출액	[매출액]	[매출액]	[매출액]
영업이익	[영업이익]	[영업이익]	[영업이익]
순이익	[순이익]	[순이익]	[순이익]

- 주요 재무 비율 분석
 - 수익성 지표:[연도]기준 ROE(자기자본이익률)는 [수치]%로 업종 평균([수치]%)을 상회. 순이익률 또한 [수치]%를 기록하며 높은 수익성을 입증.
 - 안정성 지표:부채비율은 [수치]%로 동종 업계 평균([수치]%) 대비 낮은 수준을 유지. 유동비율은 [수치]%-단기 지급 능력 또한 매우 안정적.

가짜 기밀 문서 생성 - 토큰화

II 투자 개요

1 대상 기업 개요

- 기업명 : {{company_name}} (법인등록번호: {{registration_number}})
- 대표자 : {{ceo_name}} ({{ceo_background}})
- 위치/주소 : {{hq_address}} ({{hq_description}})
- 업종/주요사업 : {{business_sector}} - {{business_products}}
- 주주 구성 : {{shareholders}}
- 주요 고객사 : {{major_clients}}
- 공급망/원자재 : {{supply_chain}}

- 매출/원가/이익률 : {{financial_performance}}
- 주요 지표/재무현황 : {{financial_indicators}}

2 투자 구조 및 요건

- 투자 방식 : {{investment_structure}}
- 투자 금액 : {{investment_amount}}
- 우선 조건 : {{investment_preference_terms}}
- Drag-along / Tag-along 권리 : {{drag_tag_rights}}
- 주요 경영참여 조건 : {{governance_participation}}
- 추가 조건 : {{additional_conditions}}

구분	경쟁사 A	경쟁사 B	경쟁사 C	대상 기업
매출	{{competitor_A_revenue}}	{{competitor_B_revenue}}	{{competitor_C_revenue}}	{{target_revenue}}
시장 점유율	{{competitor_A_share}}	{{competitor_B_share}}	{{competitor_C_share}}	{{target_share}}
주요 고객사	{{competitor_A_clients}}	{{competitor_B_clients}}	{{competitor_C_clients}}	{{target_clients}}
핵심 기술	{{competitor_A_tech}}	{{competitor_B_tech}}	{{competitor_C_tech}}	{{target_tech}}
주요 리스크	{{competitor_A_risk}}	{{competitor_B_risk}}	{{competitor_C_risk}}	{{target_risk}}

- 추가 경쟁사 정보 : {{additional_competitor_info}}

4 규제 및 정책 리스크

- 현행 규제 환경 : {{regulatory_environment_current}}
- 향후 정책 변화 : {{policy_changes_future}}
- 리스크 요약 : {{regulatory_risk_summary}}

V 재무 분석

1 과거 재무 성과 (3~5년)

- 손익계산서 요약 (P/L)

I 기업 개요 및 투자요약


1 기업 개요

- 기업명: {COMPANY_NAME}
- 대표자: {CEO_NAME}
- 주요 사업장: {HQ_ADDRESS}
- 주요 사업: {MAIN_BUSINESSES}
- 주요 고객사/계약처: {CLIENT_1}, {CLIENT_2}, {CLIENT_3}
- 주주 구성:
 - 최대주주: {MAJOR_SH_NAME} ({MAJOR_SH_PERCENT})
 - 주요 재무적 투자자: {FI_1_NAME}({FI_1_PERCENT}), {FI_2_NAME}({FI_2_PERCENT})
- 사업 규모:
 - 매출: {REVENUE_TEXT}
 - 영업이익: {OP_INCOME_TEXT}
 - 직원 수: {EMPLOYEE_COUNT_TEXT}

2 경영진 및 지배 구조

- 이사회 구성

가짜 기밀 문서 생성 - 자동화 스크립트





가짜 기밀 문서 생성 - 자동화 스크립트

The screenshot shows a GitHub repository for a user named yeji-ryu. The repository is named "-2-" and contains a file named "fake_report_gemini.py". The file is 980 lines long, 936 loc, and 59.3 KB. The script is a Python program that generates fake reports using the Faker library. It includes comments in Korean explaining the script's purpose and usage. The script uses the Faker library to generate random data, including company names, addresses, and dates. It also includes a function to generate a fake report template. The script is run using the command: `python generate_reports_fake_kr_dynamic.py --template ./template.hwp --out ./out --count 5`. The script also includes a list of required packages: `pip install faker python-dateutil tqdm`.

```
1  # -*- coding: utf-8 -*-
2  """
3  generate_reports_fake_kr_dynamic.py
4
5  - HWPX 템플릿에서 토큰 robust 추출
6  - 업종(30+), 기업규모(스타트업~대기업)별 '의미 있는' 수치/문장 생성
7  - 표/지표/현금흐름/밸류에이션이 서로 '대략 일관'되도록 계산
8  - 미지 토큰은 토큰명(영/한 키워드)로 의미 추론하여 합리적 값 생성
9  - 각 값에는 어떤 워터마크/면책도 넣지 않을 (모든 내용은 허구)
10
11
12  사용:
13  python generate_reports_fake_kr_dynamic.py --template ./template.hwp --out ./out --count 5
14
15  필요 패키지:
16  pip install faker python-dateutil tqdm
17  """
18
19  import re, os, json, time, argparse, unicodedata, random
20  from pathlib import Path
21  from zipfile import ZipFile, ZIP_DEFLATED
22  from glob import glob
23  from datetime import datetime
24  from faker import Faker
25
26  # ----- Basics -----
27  FAKER_LOCALE = "ko_KR"
28  fake = Faker(FAKER_LOCALE)
29  NOISE = r"(?:\s|<[^>]+?>|[\u200B\uFEFF\u00A0])&nbsp;)"
30  TOKEN_PLAIN_RE = re.compile(r"([\\ \ ]{2}.*?[\ \ ]\ \ ]{2})", re.DOTALL)
31  TOKEN_FAST_RE = re.compile(r"([A-Za-z0-9\u03131-\u0318E\uAC00-\u07A3_ /()\\-.%:;'\"]+?)\s*")
```

가짜 기밀 문서 생성 - 가짜 보고서

일라오이 방산 투자 보고서

Confidential - For Internal Use Only

2025. 09. 30

이 문서는 내부 검토용으로만 사용되며, 무단 복제·배포를 금합니다.

담당자	소속	HS 투자 회사	TEL	012-3456-7891
	담당자	김 현 우	Email	hshw12@gmail.com

 HS Capital
Investment,

[그린퓨처] 투자 분석 보고서

Confidential document

작성일: 2025.09.21

작성자: 애널리스트 김현우

Email: hshw12@gmail.com



HS Capital
Investment

서울특별시 성북구 삼천교로 24길 17

... 30페이지 분량의 보고서
총 30개 제작



문서 파서 구현


The screenshot shows a GitHub repository for a project named 'yeji-ryu / -2-'. The file 'docxpaser.py' is selected, showing its code. The code is a Python script that parses a document and returns a JSON object. It uses the 'docx' library to parse a Word document. The code is as follows:

```
1 import json
2 import re
3 from docx import Document
4 from docx.text.paragraph import Paragraph
5 from docx.table import Table
6 from docx.oxml.table import CT_Tbl
7 from docx.oxml.text.paragraph import CT_P
8
9 # 문서 내의 모든 블록(단락, 표)을 순회하는 함수입니다.
10 def iterBlockItems(parent):
11     # parent.element.body.iterchildren()의 각 child에 대해 반복합니다.
12     for child in parent.element.body.iterchildren():
13         if isinstance(child, CT_P):
14             yield Paragraph(child, parent)
15         elif isinstance(child, CT_Tbl):
16             yield Table(child, parent)
17
18 # 텍스트를 문장 단위로 분리하는 함수입니다.
19 def splitSentences(text):
20     # . 또는 \n 을 기준으로 문장들을 분리합니다.
21     sentences = re.split(r"[.\\n]", text)
22
23     # 공백과 빈 문자열을 제거하고, 각 문장 위에 마침표를 다시 붙여서 반환합니다.
24     return [s.strip() + "." for s in sentences if s.strip()]
25
26 # docx 파일을 파싱하고 내용을 정리하는 함수입니다.
27 def parseDocxClean(filePath):
28     doc = Document(filePath)
29     content = []
30
31     # 문서의 모든 블록을 순회합니다.
32     for block in iterBlockItems(doc):
```

```
[
  "[그린퓨처] 투자 분석 보고서.",
  "Confidential document.",
  "작성일: 2025.",
  "09.",
  "21.",
  "작성자: 애널리스트 김현우.",
  "Email: hshw12@gmail.",
  "com.",
  " | HS Capital",
  " | Investment",
  "서울특별시 성북구 삼선교로 24길 17.",
  "목차.",
  "기업 개요 및 투자 요약.",
  "기업 개요.",
  "경영진 및 지배 구조.",
  "투자 포인트 요약.",
  "사업 및 재무 분석.",
  "핵심 사업 분석.",
  "재무 성과 및 추이.",
  "비용 구조 및 수익성.",
  "산업 및 시장 동향.",
  "시장 규모.",
  "산업 성장성 분석.",
  "경쟁 환경 분석.",
  "리스크 및 기회 요인.",
  "주요 리스크 요인.",
  "성장 기회 및 미래 전략.",
  "밸류에이션 및 결론.",
  "가치 평가 모델.",
  "목표 추가 및 투자 의견.",
  "투자 시나리오 분석.",
  "부록.",
  "재무제표 요약.",
  "재무상태표.",
  "1 | 기업 개요 및 투자요약",
  "1 | 기업 개요",
  "기업명: 그린퓨처 주식회사.",
  "대표자: 이재민.",
  "주요 사업장: 강원도 강릉시 친환경산단로 88.",
  "주요 사업: 풍력, 태양광 발전, 에너지저장시스템(ESS).",
  "주요 고객사/계약처: 한전, LG에너지솔루션, 글로벌 재생에너지펀드.",
  "주주 구성:.",
  "최대주주: HS 에너지홀딩스 (32%).",
```



목차 2 진행중인 일





가짜 기밀 문서 구체화

- 영업이익: 영업이익 80→117억 (제품 믹스 개선·원가 절감)
- 당기순이익: 순이익 43→52억 (판관비 효율화·금융비용 변동)

- 재무상태표 분석

항목	2023	2024	2025
총자산 (억원)	1895	2324	2207
총부채 (억원)	1913	2347	1942
자본총계 (억원)	-18	-23	265
부채비율 (%)	101	101	88
유동비율 (%)	138	160	144

- 주요 분석 포인트 : 수익성 개선·운전자본 효율화 필요

2 주요 재무지표 추이

- 수익성 지표

ROE : 2021년 5.1% → 2025년 9.5% (최근 4년간 5.3%p 변화)

ROA : 2021년 4.1% → 2025년 6.3% (자산 효율성 점진 개선)

EBITDA Margin : 2021년 13.0% (규모의 경제·원가 구조 개선) 6.3% → 2025년

- 안정성 지표

부채비율 : 2023년 101% → 2025년 88% (리파이낸싱·만기 분산 필요)

1 가치 평가 모델

DCF(현금흐름할인법)를 주된 방법론으로 적용

DCF 모델 핵심 가정

매출액 성장률: 향후 5년간 70%에서 75%까지의 성장률 하락을 가정. 이후 장기적으로는 산업 평균에 수렴.

영업이익률: 2024 기준 12%에서 17%까지 점진적 개선 가정.

자본적 지출:향후 5년간 매출액 대비 80% 수준을 유지.


할인율 : 자본비용 85%와 부채비용 90%를 고려하여 92%의 가중평균자본비용을 적용.

영구성장률:장기 시장 성장률을 반영하여 95% 적용.

자동화를 돌렸을 때 어색하거나 부족한 부분 수정



목차 3 앞으로 할 일



1. OCR 전처리
2. PPT 기밀 문서 생성
3. Chunking 정책 수립
4. 메타데이터 설계



QnA

