

6주차 진도보고서

AI 기반 유사 문서 검출 시스템





INDEX

목차

목차1


피드백

목차2

완료한 일

목차3

앞으로 할 일





01

피드백

교수님 피드백 반영



10월 2일 피드백

피드백 요지

- 단순히 유사도 판별만 하는 것은 연구 주제로서 한계가 있음.
- 특정 도메인(금융/투자 보고서)에 한정할 필요는 없음.
- 투자 보고서에는 원래 진짜 민감한 기밀 정보가 포함되기 어렵기 때문에, "민감 리스크" 등으로 적혀 있는 것은 사실상 우리가 추론 가능한 수준이지 민감 정보라고 보기는 어려움.
- 따라서 프로젝트 목표를 유사도 판별에만 두지 말고, ****민감 정보 판별 (민감도 분석)****까지 확장하면 연구 가치가 높아짐.

결론 / Action Items

- 투자 보고서에 포함될 수 있는 진짜 민감 정보에 대해 구체적으로 정의하고, 사례를 발굴해야 함.
- 프로젝트 목표를 유사도 판별 → 유사도 + 민감도 판별로 확장하는 방안을 검토.



피드백을 반영하기 위해 회의 진행

- 기존의 투자보고서가 아닌 **내부용 투자심사보고서**로 변경하는 것이 적합하다고 판단
- 실제 사례들(기사)를 여러 개 찾아보고 관련 업종 지인들의 조언을 받으며, **기밀 문서**를 어떻게 구성하면 좋을지 고민
- 프로젝트 주제 자체가 3번 주제만 민감 정보에 관련된 내용 없이 오직 유사도만 판별하는 것이 목표지만, 너무 가벼운 프로젝트가 될 수도 있다는 교수님 의견에 따라 시간이 남으면 **민감도 판별까지 구현**해보기로 결정

https://n.news.naver.com/mnews/article/029/0002944139

디지털타임스  구독

검찰, `코로나 치료제 내부정보 활용` 신풍제약, 삼성·메리츠 증권 압수수색

 김지영 기자
입력 2025.03.27. 오후 3:46 · 수정 2025.03.27. 오후 4:48 기사원문

 2  1

장 전 대표는 2021년 4월 자체 개발한 코로나19 치료제 후보의 **임상 실패를 미리 알고** 자신이 운영하던 송암사가 보유한 신풍제약 주식을 블록딜(시간 외 매매) 방식으로 처분한 혐의를 받는다. 손실 회피액은 약 369억원으로 추정된다. 이를 통해 장 전 대표는 1562억원에 달하는 매매차익을 거둔 것으로 알려졌다. 해당 블록딜에서 매도 주관사는 메리츠증권, 매수 주관사는 삼성증권이었다.



https://n.news.naver.com/mnews/article/014/0005155816

fn **파이낸셜뉴스** **+ 구독**

PICK ⓘ

“회사 흑전이라고?”...아내 차명계좌로 주식 사들인 대표이사



김태일 기자

입력 2024.03.13. 오후 8:31 **기사원문**

1 7



| 금융위 산하 증선위, 검찰 고발 의결

금융위 관계자는 “상장사 임직원이 직무 관련 **미공개 정보를 증권 거래에 이용**하면 자본시장법, 그 과정에서 차명계좌를 활용했으면 금융실명법 위반으로도 형사처벌 대상이 될 수 있다”고 지적했다.

https://n.news.naver.com/mnews/article/009/0005315326

매일경제 ☒ 구독중

PICK ①

공개매수 발표 전날 주가 폭등...‘내부자들’ 사라져야 밸류업 성공한다 [데스크칼럼]

입력 2024.06.07. 오후 1:22 · 수정 2024.06.11. 오후 5:20 기사원문

36 23

아직도 만연한 내부정보 유출
증시와 자본시장 신뢰 흔들어
당국 범죄 성립요건 완화 통해
불공정 거래에 더 엄한 처벌을

호재성 공시가 있으면 미리 정보가 새는 일이 허다하다. 특히 최근 공개매수 대상이 된 종목들의 발표 직전 주가 흐름은 누가봐도 수상한 것이 많다.

사모펀드인 MBK파트너스가 지난 4월말 공개매수를 선언한 ‘다나와’ 운영사 커넥트웨이브가 대표적이다. 공개매수 계획이 발표되기 전 거래일에 주가는 18.6% 폭등했고, 거래량은 전일대비 40.8배나 많았다.

락앤락 주가는 사모펀드인 어피너티에쿼티파트너스가 공개매수를 발표하기 전날 11.6% 상승했다.

시작도 전에 오른 주가 때문에 기존 주주들은 실망했고, 어피너티는 지난 5일까지 공개매수 기간 연장에 나섰지만 결국 상장폐지 요건을 위한 지분 매입에 실패했다.

쌍용C&E 주식 거래량은 한앤컴퍼니가 지난 2월 공개매수 계획을 발표하기 직전 2거래일에 거래량이 평소대비 각각 8배, 5배 이상 증가하며 주가가 13% 치솟았다.

미공개 정보를 이용해서 누군가는 두둑한 돈을 챙겼음이 분명하다. 모든 거래에는 상대방이 있기 때문에 누군가에는 피눈물이 되는 일이다.



https://www.fnnews.com/news/202508201800348837

IT > IT일반

과기정통부, K-AI 결과 사전유출 의혹에 "장관에게도 보고 안 해"

장민권 기자

파이낸셜뉴스 입력 2025.08.20 18:09 수정 2025.08.20 18:09

가+ 가- ㄹ

류 차관은 **정보를 사전에 알려준 관계자가 없는지** 자체 감사 계획이 있느냐는 질문에 "업무 담당자들이나 기관 직원들에 대해 사실관계를 조사한 적이 있다"며 "경찰 수사가 진행 중인 상황이어서 결과에 따라서 적절한 조치를 검토할 필요가 있다고 생각한다"고 언급했다.


과기정통부는 독자 AI 개발 프로젝트의 참여 기업들을 선정한 외부 평가위원들이 누구였는지는 비공개이며, 정부 관련 인사는 포함돼있지 않았다고 설명했다.



02

완료한 일

수정된 WBS
벡터스토어 코드
코사인 유사도 코드
LLM 유사도 코드
업로드용 웹페이지 UI 제작
업로드용 웹페이지 구현



정규 회의 일정 #매주 월요일 3시

 깃허브 레포지토리 링크

 [WBS 및 간트차트 링크](#)

 [피그마 링크](#)

 [WBS 및 간트차트 링크 version2](#) 

[illegible]

```

print(f"📁 임베딩 불러오는 중: {EMBED_PATH}")
vectors = np.load(EMBED_PATH).astype("float32")

with open(TEXT_PATH, "r", encoding="utf-8") as f:
    docs = json.load(f)

print(f"📄 임베딩 shape: {vectors.shape}")
print(f"📄 문장 개수: {len(docs)}")

# -----
# 3. 벡터 정규화 (Cosine Similarity용)
# -----
faiss.normalize_L2(vectors)
print("✅ 벡터 정규화 완료 (L2 Norm 적용)")

# -----
# 4. FAISS 인덱스 생성 (Inner Product = Cosine Similarity)
# -----
index = faiss.IndexFlatIP(vectors.shape[1])
index.add(vectors)

# -----
# 5. 인덱스 및 문장 저장
# -----
faiss.write_index(index, str(INDEX_PATH))

```

벡터스토어 코드



임베딩된 문서 벡터를 불러와 벡터스토어로 구축

문서 임베딩 결과를 .npy 파일에서 불러와 FAISS 엔진으로 인덱싱함으로써, 실시간 유사 문서 탐색이 가능한 벡터스토어를 구현

유사도 검출 결과(코사인 유사도만 적용)

✿ [새 문서 문장 1]

1. Cosine Similarity: 1.0000
↳ I || 기업 개요 및 투자요약...
2. Cosine Similarity: 0.7818
↳ 1 | 기업 개요...

✿ [새 문서 문장 2]

1. Cosine Similarity: 1.0000
↳ 1 | 기업 개요...
2. Cosine Similarity: 0.7818
↳ I || 기업 개요 및 투자요약...

✿ [새 문서 문장 3]

1. Cosine Similarity: 1.0000
↳ 기업명: 그린퓨처 주식회사...
2. Cosine Similarity: 0.7298
↳ 그린퓨처는 친환경·재생에너지 시장의 핵심 성장 동력을 보유한 선도 기업이다. 독보적인 기술
정적인 사업 구조를 바탕으로 높은 투자 매력도를 보유한다....

✿ [새 문서 문장 4]

1. Cosine Similarity: 1.0000
↳ 대표자: 이재민...
2. Cosine Similarity: 0.6892
↳ CEO(창업주): 이재민— 기업 경영 전반 총괄, 대규모 재생에너지 프로젝트 개발/운영 경험....

코사인 유사도 코드



임베딩한 결과를 가지고 코사인 유사도 판별

문서 간 의미적 유사도를 수치화하기 위해 코사인 유사도(Cosine Similarity) 기반의 비교 알고리즘을 구현

LLM 추가 코드

```
# judge_similarity.py
# 코사인(1차) + LLM 판사(2차) 하이브리드 유사도 판정기
# - 문장/청크 단위 진행률 표시
# - 결과 JSON 저장 (지정 경로 없으면 ./results/result_<ts>.json 자동 생성)
```

```
from __future__ import annotations
import os, json, argparse, textwrap, time, pathlib, sys
from typing import List, Dict, Any, Tuple, Optional
import numpy as np
```

```
# -----
# 유틸
# -----
```

```
def l2norm(x: np.ndarray) -> np.ndarray:
    n = np.linalg.norm(x, axis=-1, keepdims=True) + 1e-12
    return x / n
```

```
def cosine_sim(a: np.ndarray, b: np.ndarray) -> np.ndarray:
    return l2norm(a) @ l2norm(b).T
```

```
def clamp01(x: float) -> float:
    return 0.0 if x < 0 else (1.0 if x > 1 else x)
```

```
def to_percent(x01: float) -> float:
    return round(clamp01(x01) * 100.0, 2)
```

```
def now_ts() -> str:
    return time.strftime("%Y%m%d_%H%M%S")
```

LLM 유사도 코드



판사 프롬프트와 API Key를 활용하여 유사도 판별

코사인 유사도 1차 필터 이후, LLM이 문맥적 연관성을 평가하도록 설계한 2단계 유사도 판정 코드를 작성하였으며, .npy 임베딩 파일과 JSON 메타 정보를 연동해 문서 수준의 의미 비교를 수행

전체 유사도 판별 결과 예시

```
{
  "query_index": 14,
  "query_text_preview": "[chunk 14]",
  "best_match": {
    "corpus_index": 11,
    "title": "",
    "section": "",
    "path": "",
    "cosine_percent": 97.99,
    "llm_percent": 80.0,
    "hybrid_percent": 90.79,
    "judge_raw": "{\"score\": 0.8, \"why\": \"투자 구조 및 조건, 거래 일정 등 핵심 투자 요소가 유사하게 나타나며, 내부 리스크와 관련된 내용도 포함되어 있어 동일한 투자 맥락\"}"
  },
  "alternatives": [
    {
      "corpus_index": 11,
      "title": "",
      "section": "",
      "path": "",
      "cosine_percent": 97.99,
      "llm_percent": 80.0,
      "hybrid_percent": 90.79,
      "judge_raw": "{\"score\": 0.8, \"why\": \"투자 구조 및 조건, 거래 일정 등 핵심 투자 요소가 유사하게 나타나며, 내부 리스크와 관련된 내용도 포함되어 있어 동일한 투자 맥락\"}"
    },
    {
      "corpus_index": 13,
      "title": "",
      "section": "",
      "path": "",
      "cosine_percent": 79.51,
      "llm_percent": 90.0,
      "hybrid_percent": 83.7,
      "judge_raw": "{\"score\": 0.9, \"why\": \"두 문서 모두 재무 분석, 밸류에이션, 리스크 분석 및 투자 구조와 조건에 대한 상세한 내용을 포함하고 있으며, 이는 동일한 내부\"}"
    }
  ]
}
```




“Confidential Investment Reports, Secured & Smart.”

“투자심사보고서를 안전하게 보관하고, 업로드한 문서의 유사도를 AI로 판별합니다.”

Login first

Uploaded Files

+ ↑



전체 문서
218 items






투자심사보고서
48 items




외부용 보고서
9/10/28 8:39PM

웹페이지 UI


- Figma로 제작
- 투자 회사 홈페이지인데 일단 업로드를 메인으로 할 수 있게 구성
- 시간적 여유가 생기면 실제 회사 홈페이지처럼 구성하여 완성도 높일 예정




Upload



Upload



Upload





완료한 일




About us

Check
permission

upload

Login

Result



웹페이지 UI 코드

<https://68e80cb9b036c6132a10f267--chipper-liger-b891aa.netlify.app/>

- 기본적인 코드만 짜놓고 업로드
부분만 코드 제대로 작성 후
netlify라는 사이트를 이용하여
링크 생성
- 추가적인 디테일은 기능 구현이
 끝나고 시간이 나면 할 예정


images	2025-10-10 오전 4:16	파일 폴더	
index	2025-10-10 오전 4:11	Chrome HTML Docu...	6KB
login.css	2025-10-10 오전 4:00	CSSfile	4KB
login	2025-10-10 오전 4:12	Chrome HTML Docu...	3KB
signup.css	2025-10-10 오전 3:59	CSSfile	3KB
signup	2025-10-10 오전 4:12	Chrome HTML Docu...	3KB
style.css	2025-10-10 오전 4:03	CSSfile	4KB
upload.css	2025-10-10 오전 4:25	CSSfile	5KB
upload	2025-10-10 오전 4:12	Chrome HTML Docu...	3KB
upload	2025-10-10 오전 4:25	JavaScript 원본 파일	4KB



03

앞으로 할 일

LLM 코드 수정
중간 발표 준비
중간 발표용 UI 구성



LLM 코드 수정



- 현재 LLM을 활용한 문맥 기반 유사도 판정 코드를 통해 기존 코사인 유사도 대비 정밀도를 향상시켰으나, 전체 실행 시간이 약 1시간으로 소요
- 향후 병렬 처리 및 모델 최적화를 통해 유사도 정확도를 유지하면서도 처리 속도를 대폭 단축시키는 방향으로 개선을 진행할 예정



중간 발표 준비



- 10월 23일에 진행될 중간 발표를 위해 2주전부터 PPT 제작 및 대본 작성을 통해 완성도 높게 중간 발표를 진행할 수 있도록 미리 준비할 예정



중간 발표용 UI 구성



- 현재 구성한 UI에서의 문제점 등을 팀원과 상의 후 수정할 예정



QnA

