


융합보안 프리캡스톤 디자인

AI 기반 문서 유사도 판별 시스템



목차

table of contents



파이프라인

최종 로직



여러 피드백을 수용해 최종 발표때까지 구현할 프로젝트 파이프라인

기밀 문서 (사전에 구현)	외부 문서 (업로드 시) 	유출 시도 시 로직
문서 파서 	문서 파서	(1)임베딩 파일끼리 코사인 유사도 판별 
문서 청킹 	문서 청킹	(2)BM25를 이용해 단어 유사도 판별
청킹된 json 임베딩 	청킹된 json 임베딩	(1)과 (2)에 대한 Hybrid 유사도
BM25에 대한 용어집에 로드 	BM25에 대한 용어집에 새로 업로드	결과 답변을 LLM을 사용해 보여줌

한 일 목록

임베딩, 벡터스토어 모델 선정

BM25 용어집 코드

코사인 유사도 비교 코드

임베딩 모델 선정

임베딩

- BGE-M3 (1024)
- BGE-M3-Korean (1024)
- BGE-M3-ko (1024)
- KoSimCSE (768, 한국어 특화)
- E5-KR (768, 한국어 특화)

- 총 5가지 모델을 역할을 나눠서 임베딩 코드 작성
- npy 파일을 5개의 코드에 넣어서 결과값끼리 비교하는 코드 작성
- 결과에 따른 비교 표를 만들고, 회의를 통해 모델 선정

한 일 목록

임베딩, 벡터스토어 모델 선정

BM25 용어집 코드

코사인 유사도 비교 코드

```
# -----
parser = argparse.ArgumentParser(description="Embedding model selection")
parser.add_argument("--in", dest="input_path", required=True)
parser.add_argument("--outdir", dest="out_dir", default="output")
parser.add_argument("--batch-size", dest="batch_size", default=100)
args = parser.parse_args()

INPUT_PATH = Path(args.input_path).resolve()
OUT_DIR = Path(args.out_dir).resolve() if args.out_dir else Path(".").resolve()

OUT_DIR.mkdir(parents=True, exist_ok=True)

# 파일명 접두사: 입력 파일명(stem)
prefix = INPUT_PATH.stem
NPY_PATH = OUT_DIR / f"{prefix}_embeddings.npy"
JSON_PATH = OUT_DIR / f"{prefix}_embeddings.json"

# -----
# 1. 모델 로드
# -----
MODEL_NAME = "BAAI/bge-m3"
device = torch.device("cuda" if torch.cuda.is_available() else "cpu")

tokenizer = AutoTokenizer.from_pretrained(MODEL_NAME)
model = AutoModel.from_pretrained(MODEL_NAME)
model.eval()
```

BGE-M3

- 영어·중국어·한국어 등 **다국어 문서**를 효율적으로 이해하고 검색하기 위해 설계된 **고성능 멀티언어 임베딩 모델**

한 일 목록

임베딩, 벡터스토어 모델 선정

BM25 용어집 코드

코사인 유사도 비교 코드

```
from sentence_transformers import SentenceTransformer

# -----
# CLI
# -----
parser = argparse.ArgumentParser(description="Embedding CLI")
parser.add_argument("--in", dest="input_path", required=True)
parser.add_argument("--outdir", dest="out_dir", default="out_dir")
parser.add_argument("--batch-size", dest="batch_size", default=100)
args = parser.parse_args()

INPUT_PATH = Path(args.input_path).resolve()
OUT_DIR = Path(args.out_dir).resolve() if args.out_dir else Path(".").resolve()
OUT_DIR.mkdir(parents=True, exist_ok=True)

prefix = INPUT_PATH.stem
NPY_PATH = OUT_DIR / f"{prefix}_embeddings1.npy"
JSON_PATH = OUT_DIR / f"{prefix}_embeddings1.json"

MODEL_NAME = "upskyy/bge-m3-korean"

# -----
# JSON 로더
# -----
def load_texts(path: Path):
    with open(path, "r", encoding="utf-8") as f:
        data = json.load(f)
```

bge-m3-korean

- BGE-M3를 한국어 데이터로 재 학습한 한국어 특화 임베딩 모델로, 문서 검색·유사도 판단·QA 작업 등에서 높은 정확도를 제공

한 일 목록

임베딩, 벡터스토어 모델 선정

BM25 용어집 코드

코사인 유사도 비교 코드

```
from sentence_transformers import SentenceTransformer

# -----
# CLI
# -----
parser = argparse.ArgumentParser(description="Embedding model CLI")
parser.add_argument("--in", dest="input_path", required=True)
parser.add_argument("--outdir", dest="out_dir", default="output")
parser.add_argument("--batch-size", dest="batch_size", default=100)
args = parser.parse_args()

INPUT_PATH = Path(args.input_path).resolve()
OUT_DIR = Path(args.out_dir).resolve() if args.out_dir else Path("output")
OUT_DIR.mkdir(parents=True, exist_ok=True)

prefix = INPUT_PATH.stem
NPY_PATH = OUT_DIR / f"{prefix}_embeddings.npy"
JSON_PATH = OUT_DIR / f"{prefix}_embeddings.json"

MODEL_NAME = "dragonkue/BGE-m3-ko"

# -----
# JSON 로더
# -----
def load_texts(path: Path):
    with open(path, "r", encoding="utf-8") as f:
        data = json.load(f)
```

BGE-m3-ko

- 한국어 중심으로 미세 조정된 다국어 임베딩 모델로, 텍스트 의미를 벡터로 변환해 문장·문서 유사도 분석과 검색 성능을 강화한 버전

한 일 목록

임베딩, 벡터스토어 모델 선정

BM25 용어집 코드

코사인 유사도 비교 코드

```
print("--- 스크립트 실행 시작 ---")

import json
import numpy as np
from sentence_transformers import SentenceTransformer
import time # 시간 측정을 위해 time 모듈 추가

# 1. KoSimCSE 모델 로드
# 가장 성능이 좋은 roberta-multitask 모델을 사용합니다.
# (다른 모델: 'BM-K/KoSimCSE-bert-multitask', 'BM-K/KoSimCSE-roberta')
try:
    print("KoSimCSE 모델을 로드합니다... (BM-K/KoSimCSE-roberta-multitask)")
    model_name = './KoSimCSE-roberta-multitask' # 로컬 경로 사용
    model = SentenceTransformer(model_name)
    print("모델 로드 완료.")
except Exception as e:
    print(f"모델 로드 중 오류 발생: {e}")
    print("모델 경로('./KoSimCSE-roberta-multitask')가 올바른지 확인하세요.")
    exit()

# 2. JSON 파일에서 데이터 로드하는 함수
def load_sentences_from_json(file_path):
    """
    JSON 파일에서 문장 리스트를 로드합니다.
    파일 형식: ["문장1", "문장2", ...]
    """
    try:
```

KoSimCSE

- 한국어 문장을 벡터로 변환해 의미적 유사도 계산을 수행하는 한국어 전용 Sentence-BERT 임베딩 모델로, 문장 검색·클러스터링·QA 등 다양한 자연어 처리 작업에 활용

한 일 목록

임베딩, 벡터스토어 모델 선정

BM25 용어집 코드

코사인 유사도 비교 코드

```
print("--- 스크립트 실행 시작 ---")

import json
import numpy as np
from sentence_transformers import SentenceTransformer
import time # 시간 측정을 위해 time 모듈 추가

# 1. E5-KR 모델 로드
try:
    # E5-KR 모델은 'intfloat/multilingual-e5-large'를 사용합니다.
    # (더 작은 모델이 필요하다면 'intfloat/multilingual-e5-base' 사용)
    print("E5-KR 모델을 로드합니다... (intfloat/multilingual-e5-large)")

    # 이 모델은 처음 실행 시 KoSimCSE처럼 자동으로 다운로드됩니다.
    # (시간이 몇 분 소요될 수 있습니다.)
    model_name = 'intfloat/multilingual-e5-large'
    model = SentenceTransformer(model_name)
    print("모델 로드 완료.")
except Exception as e:
    print(f"모델 로드 중 오류 발생: {e}")
    print("인터넷 연결을 확인하거나 모델 이름이 올바른지 확인하세요.")
    exit()

# 2. JSON 파일에서 데이터 로드하는 함수 (이전과 동일)
def load_sentences_from_json(file_path):
    """
    JSON 파일에서 문장 리스트를 로드합니다.
    파일 형식: [{"문장1"}, {"문장2"}]
    """
```

e5-large

- 100개 이상의 언어를 지원하는 **대규모 다국어 임베딩 모델**로, 문장 의미를 벡터로 표현해 검색, 분류, 유사도 계산 등에 높은 성능을 보이는 E5 시리즈의 확장 버전

한 일 목록

임베딩, 벡터스토어 모델 선정

BM25 용어집 코드

코사인 유사도 비교 코드

임베딩 모델 비교 코드

```
import argparse, numpy as np
from pathlib import Path

def l2norm(X):
    n = np.linalg.norm(X, axis=1, keepdims=True) + 1e-12
    return X / n

def isotropy_stats(Xu):
    mean_vec = Xu.mean(axis=0)
    mean_norm = float(np.linalg.norm(mean_vec))
    # 코사인 분포 요약 (무작위 일부 샘플)
    n = len(Xu)
    idx = np.random.default_rng(0).choice(n, size=min(5000, n), replace=False)
    S = Xu[idx] @ Xu[idx].T
    iu = np.triu_indices(len(idx), k=1)
    sims = S[iu]
    return {
        "mean_norm": mean_norm,
        "cos_mean": float(sims.mean()),
        "cos_std": float(sims.std())
    }

def spectral_stats(Xu):
    # SVD on centered embeddings
    Xc = Xu - Xu.mean(axis=0, keepdims=True)
    # economy SVD
    U, S, Vt = np.linalg.svd(Xc, full_matrices=False)
    s2 = S**2
    tot = s2.sum() + 1e-12
    top_ratio = float(s2[0] / tot)
    # effective rank (entropy of normalized eigenvalues)
    p = s2 / tot
    ent = -np.sum(p * (np.log(p + 1e-12)))
    eff_rank = float(np.exp(ent))
    return {"top_var_ratio": top_ratio, "eff_rank": eff_rank}
```

모델 비교 코드

- 임베딩 벡터(.npy)를 정규화해 등방성·스펙트럼(분산/유효랭크)·허브니스 지표와 교차 kNN 겹침을 산출하고 표 형태 보고서를 출력/저장하는 비교

이번주 한 일

10월 30일~11월 5일



한 일 목록

임베딩, 벡터스토어 모델 선정

BM25 용어집 코드

코사인 유사도 비교 코드

모델 비교 결과

=== Per-model intrinsic metrics ===

model	N	D	mean_norm	cos_mean	cos_std	top_var_ratio	eff_rank	hub_skew	hub_gini
A	250	1024	0.651283	0.421858	0.080292	0.071103	101.855362	1.280884	1.333683
B	250	1024	0.525356	0.273091	0.096815	0.058242	101.256721	1.725596	1.366256
C	250	1024	0.529652	0.277642	0.086800	0.063709	108.785828	0.902368	1.332435
D	250	1024	0.911753	0.830616	0.038440	0.113194	81.538506	1.158413	1.392054
E	250	768	0.563077	0.314312	0.123637	0.083994	70.455711	1.110628	1.371891

해석 가이드:

- mean_norm ↓, cos_mean ↓ → 과도한 수렴/붕괴 위험 낮음.

- top_var_ratio ↓, eff_rank ↑ → 유효 차원 큼(표현 다양성).

- hub_skew ↓, hub_gini ↓ → 허브 문제 적음(바이어스 감소).

교차 kNN 검색 행렬(k=10):

	A	B	C	D	E
A	-	0.634400	0.813600	0.610000	0.482000
B	0.634400	-	0.636000	0.461600	0.509600
C	0.813600	0.636000	-	0.582800	0.482800
D	0.610000	0.461600	0.582800	-	0.441600
E	0.482000	0.509600	0.482800	0.441600	-



임베딩 모델 비교 결과 표

임베딩 모델 비교표

구분	A	B	C	D	E
핵심 평가	쓸림·유사도 과다 (변별력↓)	이소트로피 최고 수준(쓸림 최소)	종합 1위: 균형·표 현력·허브니스 모 두 우수	최악의 쓸림(붕괴 에 근접)	표현 다양성 부족 (차원 768)
장점	A-C 겹침 0.814 로 C와 구조 유사	cos_mean↓, top_var_ratio↓ (분포 안정)	cos_mean↓, top_var_ratio↓, eff_rank↑(108.8)	없음(숫자상 이점 미미)	안정성은 무난, 허 브 지표 과도하진 않음
단점	cos_mean 높음 (0.422) → 전체 가 비슷해 보임	허브니스 상대적 으로 불리(국소 허 브 위험)	특별한 단점 없음 (전반 균형)	cos_mean 0.831, top_var_ratio 0.113, eff_rank 81.5 (심각한 쓸 림)	eff_rank 최저 (70.5), top_var_ratio 높 음
권장 용도	유지 필요 X (C로 대체 권장)	"아주 뻣뻣한 근 접" 선호 시 A/B 보조	운영 기본 모델로 채택	사용 비권장	경량/호환 필요 시 임시 대안
참고 메모	A-C 겹침 0.814 (전환 안정성 높 음)	A-B 겹침 0.634	A-C 겹침 0.814 (최고)	A-D 겹침 0.610	A-E 겹침 0.482



임베딩 모델 비교 결과 표

구분	A	B	C	D	E
핵심 평가	쓸림이 약간 있음 (조금 편향됨)	쓸림 거의 없음 (가장 안정적)	✓ 균형이 가장 좋음 (1등)	쓸림 심함 (불균 형)	표현 다양성 부족 (차원 작음)
장점	구조가 안정적, 다 른 모델과 유사	분포가 고르게 퍼 짐	균형 최고, 다양성 도 좋음	없음 (성능 낮음)	안정적이고 편향 없음
단점	전체적으로 너무 비슷하게 나옴	국소 허브 문제 가 능	특별한 단점 없음	쓸림 심하고 불균 형	다양성 부족 (표현 이 단조로움)
추천 용도	C로 대체 가능 (균 이 유지 X)	실험용 A/B 테스 트 시 사용	✓ 기본 모델로 사용 권장	사용 비추천	임시로만 사용
안정성 비교 (유사 도)	A-C: 0.814 (높음)	A-B: 0.634	A-C: 0.814 (최고)	A-D: 0.610	A-E: 0.482

한 일 목록

임베딩, 벡터스토어 모델 선정

BM25 용어집 코드

코사인 유사도 비교 코드

벡터스토어 모델 선정

벡터스토어

- FAISS (밀집)
- Chroma
- 쿼더런트 -유 (희소, 밀집 둘다 가능)
- Pinecone -한 (희소, 밀집 둘다 가능)

- 기존에 벡터스토어를 FAISS 모델을 사용해서 코드를 구현했었지만, BM25를 도입하고 희소 벡터도 저장할 수 있는 모델이 필요 -> 이를 기준으로 모델 선정



벡터스토어 모델 - Qdrant

```
(my_project_env) PS C:\Users\LG> python save_to_qdrant.py
'docxchunk.json'에서 원본 텍스트를 로드합니다...
'embeddings_e5.npy'에서 임베딩 벡터를 로드합니다...
총 250개의 텍스트와 벡터를 로드했습니다.
Qdrant 클라이언트를 초기화합니다. (저장 경로: ./qdrant_storage)
기존 컬렉션 'my_document_store'을(를) 삭제합니다.
새 컬렉션 'my_document_store'을(를) 생성합니다.
컬렉션 준비 완료.
데이터를 Qdrant 형식으로 변환합니다...
'my_document_store' 컬렉션에 250개의 데이터를 업로드합니다...
업로드 완료! (소요 시간: 2.35초)

Qdrant 스토어 'my_document_store'에 저장된 총 데이터 수: 250
이제 './qdrant_storage' 폴더에 벡터 데이터가 영구적으로 저장되었습니다.
Qdrant 클라이언트를 닫습니다.
스크립트 실행 완료.
```

이번주 한 일

10월 30일~11월 5일



벡터스토어 모델 - Pinecone

Pinecone / 동균's Org / Default / Database

Docs Settings Get help 동한

Get started
Database
Indexes (3)
Backups
Assistant
Inference
API keys
Manage

STARTER USAGE ⓘ
Upgrade now

Namespace: conf Operation: Search by ID ID: 0 Top K: 10
+ Filter + Rerank Search

Search: 10 results (top_k=10) 1 RUs ⓘ

1	ID: 0 text: "그린퓨처 투자 분석 보고서"	...
SCORE 1.0003		
2	ID: 244 text: "그린퓨처 정기보고서 및 공시자료"	...
SCORE 0.7290		
3	ID: 33 text: "기업명: 그린퓨처 주식회사"	...

오전 12:17
2025-11-06

벡터스토어 모델 비교 결과 표

 벡터스토어 비교 및 선정 결과

구분	유형	희소 벡터 지원	밀집 벡터 지원	웹 관리 인터페이스	비용	비고
FAISS	로컬/오픈소스	✗	✓	✗	무료	속도 빠르지만 희소벡터 미지원
Chroma	로컬/오픈소스	✗	✓	● (간단)	무료	간편하지만 대규모 서비스에 부적합
Qdrant	서버형/오픈소스	✓	✓	● (웹 대시보드 제공)	무료	희소·밀집 모두 지원, 실무 배포 적합 → ✓ 선정
Pinecone	클라우드형(SaaS)	✓	✓	✓ (가독성 높은 웹 UI)	⚠ 5개 이상 유료	기능 우수하나 현실적 비용 부담

이번주 한 일

10월 30일~11월 5일



한 일 목록

임베딩, 벡터스토어 모델 선정

BM25 용어집 코드

코사인 유사도 비교 코드

bm25

```
from rank_bm25 import BM25Okapi
from collections import Counter, defaultdict
from pathlib import Path
from typing import List, Tuple, Dict
import numpy as np
import json
from scipy.sparse import csr_matrix, save_npz, load_npz
import argparse
import re
import unicodedata

# ----- pretty JSON -----
def write_pretty_json(path: str | Path, obj) -> None:
    Path(path).write_text(
        json.dumps(obj, ensure_ascii=False, indent=2, separators=(",", ":")),
        encoding="utf-8"
    )

def normalize_text(s: str) -> str:
    """NFC 정규화 + zero-width space 제거"""
    return unicodedata.normalize("NFC", s).replace("\u200b", "")

# ===== Tokenizers =====
_KOREAN_RE = re.compile(r"[가-힣]")

def _tokenize_simple(text: str) -> List[str]:
    text = re.sub(r"[^0-9a-zA-Z가-힣]+", " ", text)
    return [t for t in text.strip().split() if t]

def _tokenize_okt_nouns(text: str) -> List[str]:
    from konlpy.tag import Okt
    okt = Okt()
    return [t for t in okt.nouns(text) if len(t) >= 2]
```

BM25 용어집 코드

- rank_bm25를 사용해 코드 작성

BM25 문서간 분리

```
"솔라웨이브 내부 경영자료 및 파일럿 프  
"한국재생에너지정책연구원(가상) 태양광  
"그로스파이낸스벤처스(가상 VC) 투자 심  
"산업 관련 학술 논문 및 주요 시장 뉴스  
"---",  
"사이온모터스 투자 분석 보고서",  
"Confidential documen",  
"작성일: 2025-09-23",  
"작성자: 애널리스트 김현우",  
"Email: wonseop82@korea.kr",
```

```
{  
  "row": 278,  
  "doc_id": "솔라웨이브 투자 분석 보고서"  
},  
{  
  "row": 279,  
  "doc_id": "솔라웨이브 투자 분석 보고서"  
},  
{  
  "row": 280,  
  "doc_id": "솔라웨이브 투자 분석 보고서"  
},  
{  
  "row": 281,  
  "doc_id": "사이온모터스 투자 분석 보고서"  
},  
{  
  "row": 282,  
  "doc_id": "사이온모터스 투자 분석 보고서"  
},  
{
```




BM25 단어집 예시

"특징": 157,
"의결권": 158,
"투명": 159,
"의사": 160,
"결정": 161,
"강화": 162,
"사외": 163,
"이사": 164,
"법률": 165,
"정책": 166,
"전문가": 167,
"고문단": 168,
"운영": 169,
"신흥": 170,
"플레이어": 171,
"단계": 172,
"가능": 173,
"차별": 174,
"기술력": 175,
"바탕": 176,
"매력": 177,
"성장세": 178,
"전년": 179,


한 일 목록

임베딩, 벡터스토어 모델 선정

BM25 용어집 코드

코사인 유사도 비교 코드

218, 리모
458, 상명
502, 사와
658, 력사
735, 혁신지
736, 원법
762, 인법
948, 단과
1028, 색사
1201,페이먼



오차에 관한 피드백

- 1200개 정도의 단어를 추출했을 때 사진과 같이 12개의 이상한 결과값 -> 이런 약 1% 오차에 관해서 여쭙본 결과, 상용 환경에서도 흔하게 용인될 수 있는 결과라는 피드백



소만사 김정한 팀장님

1퍼센트 정도면 상용 환경에서도 흔하게 용인될 수 있는 수치일것 같습니다. 임베딩 모델이 모든 단어가 학습 되어 있지는 않습니다.

한 일 목록

임베딩, 벡터스토어 모델 선정

BM25 용어집 코드

코사인 유사도 비교 코드

```
▼ embedding_result
{} flexwavepay_chunk_embeddings.json
≡ flexwavepay_chunk_embeddings.npy
{} futurebattery_chunk_embeddings.json
≡ futurebattery_chunk_embeddings.npy
{} greenfuture_chunk_embeddings.json
≡ greenfuture_chunk_embeddings.npy
{} hydrogentech_chunk_embeddings.json
≡ hydrogentech_chunk_embeddings.npy
{} ivanfarm_chunk_embeddings.json
≡ ivanfarm_chunk_embeddings.npy
{} jannawindtech_chunk_embeddings.json
≡ jannawindtech_chunk_embeddings.npy
{} leonaconstruction_chunk_embeddings.json
≡ leonaconstruction_chunk_embeddings.npy
{} medicuresolutions_chunk_embeddings.json
≡ medicuresolutions_chunk_embeddings.npy
{} mundopharm_chunk_embeddings.json
≡ mundopharm_chunk_embeddings.npy
{} neobiosense_chunk_embeddings.json
≡ neobiosense_chunk_embeddings.npy
{} nextfintech_chunk_embeddings.json
≡ nextfintech_chunk_embeddings.npy
{} nunufactory_chunk_embeddings.json
≡ nunufactory_chunk_embeddings.npy
{} raumcivil_chunk_embeddings.json
≡ raumcivil_chunk_embeddings.npy
```

문서 15개 npy,json

- 문서 15개를 임베딩한 결과 파일인 npy와 json을 이용해 벡터스토어 쿼터런트를 이용해 코사인 유사도 비교 코드 구현

이번주 한 일

10월 30일~11월 5일



한 일 목록

임베딩, 벡터스토어 모델 선정

BM25 용어집 코드

코사인 유사도 비교 코드

qdrant_client 코드

- 일단 Topk를 10개, 나머지 파라미터 값이나 수치는 GPT가 추천해준 수치로 설정

```
rank_full_doc2doc_strict.py > ...
1 # rank_full_doc2doc_strict.py
2 import os, json, argparse, datetime
3 import numpy as np
4 from qdrant_client import QdrantClient, models
5
6 # ===== Qdrant / 차원 등 환경 =====
7 QDRANT_PATH = "./qdrant_storage"
8 DOC_COLLECTION = "my_document_store"
9 VECTOR_DIM = 1024
10
11 # ===== 랭킹/점수 파라미터 =====
12 TOPK = 10
13 MAX_QUERY_CHUNKS = 2000
14 MAX_CAND_CHUNKS = 2000
15 SEED = 42
16
17 # 디바이싱(템플릿 제거)용 PCA
18 PCA_SAMPLE_PER_DOC = 200 # 각 문서에서 최대 N개 샘플 벡터를 뽑아 PCA
19 PCA_COMPONENTS = 12 # 제거할 공통 성분 개수(k). 8~16 사이 권장
20
21 # 보수적 점수화
22 PERCENTILE = 0.80 # 상위 80% 구간 평균 (퍼센타일-평균)
23 TRIM_RATIO = 0.05 # 상/하위 5% 잘라낸 트림 평균
24 COVER_TAU_HIGH = 0.85 # 강한 커버리지 기준 1
25 COVER_TAU_VHIGH = 0.90 # 강한 커버리지 기준 2
26
27 # ===== 유틸 =====
28 def l2n(m): # row-wise normalize
29     d = np.linalg.norm(m, axis=1, keepdims=True) + 1e-12
30     return m / d
31
32 def sample_rows(m, cap, seed=SEED):
33     if cap is None or m.shape[0] <= cap:
```




외부 문서와 코사인 유사도 비교 결과

```
PS C:\Users\LG> python rank_full_doc2doc.py "C:\Users\LG\greenfuture_chunk_embeddings.npy"

Content-sim (PCA-debiased & strict) - Top-10 for 'C:\Users\LG\greenfuture_chunk_embeddings.npy':
1. futurebattery      DocSim=0.7357 PctMean_Q→C=0.7725 PctMean_C→Q=0.7828 Trim_Q→C=0.6891 Trim_C→Q=0.6983 Cov85_Q→C=36.8% Cov85_C→Q=37.9% Cov90_Q→C=36.0% Cov90_C→Q=37.0
% [Q=250, C=243]
2. nextfintech        DocSim=0.7221 PctMean_Q→C=0.7720 PctMean_C→Q=0.7585 Trim_Q→C=0.6857 Trim_C→Q=0.6723 Cov85_Q→C=36.8% Cov85_C→Q=35.5% Cov90_Q→C=35.2% Cov90_C→Q=34.0
% [Q=250, C=259]
3. medicuresolutions DocSim=0.7155 PctMean_Q→C=0.7659 PctMean_C→Q=0.7588 Trim_Q→C=0.6729 Trim_C→Q=0.6643 Cov85_Q→C=38.0% Cov85_C→Q=37.4% Cov90_Q→C=35.6% Cov90_C→Q=34.6
% [Q=250, C=257]
4. neobiosense        DocSim=0.7018 PctMean_Q→C=0.7461 PctMean_C→Q=0.7489 Trim_Q→C=0.6543 Trim_C→Q=0.6580 Cov85_Q→C=35.6% Cov85_C→Q=35.8% Cov90_Q→C=34.0% Cov90_C→Q=33.9
% [Q=250, C=254]
5. flexwavepay        DocSim=0.6795 PctMean_Q→C=0.7262 PctMean_C→Q=0.7281 Trim_Q→C=0.6297 Trim_C→Q=0.6341 Cov85_Q→C=34.8% Cov85_C→Q=35.1% Cov90_Q→C=33.2% Cov90_C→Q=33.5
% [Q=250, C=248]
6. hydrogentech       DocSim=0.6593 PctMean_Q→C=0.7171 PctMean_C→Q=0.6877 Trim_Q→C=0.6323 Trim_C→Q=0.6003 Cov85_Q→C=32.0% Cov85_C→Q=29.3% Cov90_Q→C=31.2% Cov90_C→Q=28.6
% [Q=250, C=273]
7. jannawindtech      DocSim=0.6321 PctMean_Q→C=0.6766 PctMean_C→Q=0.6742 Trim_Q→C=0.5923 Trim_C→Q=0.5853 Cov85_Q→C=30.8% Cov85_C→Q=30.7% Cov90_Q→C=30.4% Cov90_C→Q=30.3
% [Q=250, C=251]
8. sionmotors         DocSim=0.6264 PctMean_Q→C=0.6692 PctMean_C→Q=0.6770 Trim_Q→C=0.5750 Trim_C→Q=0.5845 Cov85_Q→C=32.0% Cov85_C→Q=32.0% Cov90_Q→C=32.0% Cov90_C→Q=32.0
% [Q=250, C=250]
9. solarwave          DocSim=0.6037 PctMean_Q→C=0.6596 PctMean_C→Q=0.6320 Trim_Q→C=0.5781 Trim_C→Q=0.5452 Cov85_Q→C=24.4% Cov85_C→Q=22.8% Cov90_Q→C=23.6% Cov90_C→Q=21.0
% [Q=250, C=281]
10. nunufactory       DocSim=0.2986 PctMean_Q→C=0.3366 PctMean_C→Q=0.3004 Trim_Q→C=0.2954 Trim_C→Q=0.2620 Cov85_Q→C=0.4% Cov85_C→Q=0.2% Cov90_Q→C=0.4% Cov90_C→Q=0.2% [
Q=250, C=410]
```


이번주 한 일

10월 30일~11월 5일

임시 외부 문서

"글로벌 뷰티판을 뒤엎는 K-Beauty: '에프면 다아?'라 묻는 당신에게"
필 이름: 에프면다아 (홍리미윤에디션)

<목차>

1. 서론
2. 본론
 - 2-1. 뷰티 산업 현황
 - 2-2. 주요 국가별 시장 현황
 - 2-3. 화장품 산업
 - 2-4. 미용기기 산업
3. 주요 기업분석
4. K-뷰티 산업 리스크
5. 결론

1. 서론

K-뷰티는 이제 단순한 트렌드를 넘어, 글로벌 미용 산업의 핵심적인 아이콘으로 자리잡고 있다. 한국의 뷰티 제품들은 피스널 다양함을 반영한 스킨케어와 메이크업 솔루션을 통해서 소비자들에게 새로운 미용 경험을 제공한다. 이는 특히 젊은 세대에서 폭발적인 인기를 끌고 있다.

한국무역협회에 따르면 2023년 기준으로 K-뷰티 시장의 규모는 13조 원에 달하며, 이 중 10조원 가량이 글로벌 시장으로의 수출액으로 나타났다. K-뷰티는 스킨케어, 색조화장품 뿐만 아니라 미용기기까지 아우르는 포괄적인 산업을 의미한다. 그중 한국의 스킨케어 제품은 전 세계 50% 이상의 점유율을 차지하며 쿠팡, 파운데이션과 같은 기초 메이크업 제품은 한국 시장에서 약 3,000억 원의 매출을 기록하였다.

이러한 성장은 한국의 뷰티 브랜드들이 최신 기술과 트렌드를 잘 반영하여 소비자들의 니즈에 맞는 제품을 제공하고 있음을 보여준다. 예를 들어, 메디뷰트의 에이지링 하이 포커스 샷은 정밀 타겟 집중 초음파(하이푸) 기술을 사용하여 소비자들이 집에서 간편하게 피부 관리를 할 수 있도록 돕는다.

K-뷰티는 앞으로도 지속적인 성장이 예상되며, 2024년에는 시장 규모가 16조 원에 이를 것으로 보인다. 이러한 성장 가능성을 바탕으로 우리는 K-뷰티 산업의 다양한 측면을 분석하고 K-뷰티의 현재와 미래를 종합적으로 평가하여 지속 가능한 성장을 위한 방향성을 모색할 것이다. 또한 산업의 현황과 미래 방향을 규명하여, 한국의 뷰티 제품들이 글로벌 시장에서 경쟁력을 강화하고 지속 가능한 성장을 이룰 수 있는 전략적 방안을 제시하고자 한다. K-뷰티는 단순한 화장품 시장을 넘어, 문화와 기술이 융합된 새로운 형태의 산업으로서 추후 대한민국 미래 먹거리로 성장할 가능성이 높다.


2. 본론

2-1 뷰티 산업 현황

| 전세계 화장품 소매시장 규모




현재 글로벌 뷰티 시장은 2024년까지 약 8,160억 달러에 달할 것으로 예상된다. 그 중 K-뷰티 시장은 약 132억 달러에 이를 것으로 예상된다. 특히 스킨케어와 색조화장품 부문에서의 성장이 두드러진 성과를 보이고 있다. 특히나, 글로벌 스킨케어 시장 규모는 23년 7억 4,420만 달러로 평가되었으며, 24년에서 30년까지 연평균 성장 5.6%로 성장할 것으로 예상된다. 과거와 달리 '지속 가능성'과 '물린 뷰티'에 대한 관심이 높아지면서 건강하고 빛나는 피부를 유지하는 트렌드로의 변화로 글로벌 뷰티 시장의 판도가 변화하고 있다. 또한, 스킨케어 뿐만 아니라 섹서, 마스크리트, 아이메이크업 등의 개인 관리 미용 외식이 높아짐에 따라 화장품에 대한 수요도 촉진하며 성장하고 있다.



특히나, 화장품은 대표적인 교역 소비재로 특정 인증, 계층에 국한되지 않고 다양함을 무기로 화장품의 세계 시장 규모는 지속적으로 성장하는 모습을 보이고 있다. 또한, 과거 여정에 국한되어 있던 뷰티 산업은 스킨케어, 자기 수질 및 웰빙 등의 다양한 시장으로 확산되었다. 뷰티 (Beauty)와 그루밍 (Grooming)은 성별과 세대를 불문한 필수 요소로 남용용 제품군의 확장 및 10대 소비층으로의 산업 확장으로 그루밍은 단순 청결 관리를 넘어선 치안감과 심의 장식 요소를 높이는 중요한 요소로 자리매김하였다. 이러한 글로벌 뷰티 시장의 판도 변화에 따라 시장의 규모는 다각화되어 발전하고 있다. 이에 한국 무역협회 KITA에 따르면 뷰티 시장은 팬데믹 이후 2028년까지 연평균 4.2%의 성장할 것으로 전망하고 있다. 지속적인 혁신을 통한 새로운 뷰티 트렌드는 대형 브랜드의 점유율을 뺏으며, 많은 인디 브랜드의 투어를 나타내 시장에 새로운 활력을 불어넣고 있다. 이들은 다양한 소비자들의 피부 타입 및 존 등의 취향을 고려한 맞춤형 제품을 출시해 선택의 폭을 넓히는 등 발전하면서 변화와 가져왔다.

| 2023년 소비재 품목별 수출비중




화장품은 소비재 시장 중 자동차 다음으로 수출 비중이 높은 품목으로 2023년 전체 0.2%를 차지하면서 전세 소비재 적자 전환에도 불구하고 무역 흑자를 지속적으로 확대하였다. 이에 우리나라 전체 수출 활동 기업의 수가 지속적으로 증가하면서 무역에서의 존재감이 부각된다.

| 화장품 수출액 및 수출비중



과거 중국에 국한되어 있던 뷰티 시장이 현재 아시아 태평양 지역과 북미 시장으로 확장되어 다양한 소비자에게 화장품을 제공하며, K-뷰티가 가진 '맞춤형'과 '물린 뷰티'의 최신 트렌드로 글로벌 뷰티 시장에서 핵심 플레이어로서의 역할을 공고히 하였다. 꾸준한 성장은 수출 증가로 이어지며 수입은 비교적 일정한 수준으로 유지되어 한국의 화장품 시장 규모를 키워나가 2018년에는 수출액이 처음으로 50억 달러를 돌파하여 업계의 국제적 영향력이 커지고 있음을 보여주었으며 2021년 수출은 78억 6천만 달러에 달해 역대 최고치를 달성하였다.



글로벌 화장품 시장에서 한국은 세계 10위를 차지하였으며, 24년에는 133억 4천만 달러로 성장 가능성을 보여준다. 특히나, SNS의 중요성이 대두되는 현대에 K-pop의 발전, 해외 인플루언서들의 제품 소개가 소비자들의 직구로 이어져 2024년 17.5개국으로 수출로 역대 최대 국가에 수출하였으며, 110개 국가에서의 최대 실적도 기록하였다.

주요 기업 및 시장 점유율

4. 책임판매업체 생산실적 (생산액 1,000억 이상)

순위	기업명	2022년 실적		순위	기업명	2023년 실적	
		생산액	점유율			생산액	점유율
1	LG화학	133,909	100.0	1	LG화학	145,102	100.0
2	SK케미칼	34,819	25.7	2	SK케미칼	34,954	24.1
3	SK케미칼	34,262	25.2	3	SK케미칼	34,340	23.3
4	SK케미칼	2,700	2.0	4	SK케미칼	2,740	2.2
5	SK케미칼	1,835	1.4	5	SK케미칼	1,766	1.2
6	SK케미칼	1,780	1.3	6	SK케미칼	1,692	1.1
7	SK케미칼	1,531	1.1	7	SK케미칼	1,584	1.1
8	SK케미칼	1,176	0.9	8	SK케미칼	1,481	1.0
9	SK케미칼	890	0.7	9	SK케미칼	1,377	0.9
10	SK케미칼	695	0.5	10	SK케미칼	1,164	0.8
11	SK케미칼	684	0.5	11	SK케미칼	1,103	0.8
12	SK케미칼	687	0.5	12	SK케미칼	1,104	0.8
13	SK케미칼	607	0.5	13	SK케미칼	1,018	0.7

24.05.20 식약처에서 발표한 '23년 생산·수입·수출 실적' 보고서에 따르면 LG생활건강은 2023년 생산금액 약 3조 5천억원으로 점유율 24.1%를 차지하며 한국 화장품에서 가장 큰 기업이 되었다. LG는 프리미엄 스킨케어에 대한 투자와 국제 시장에서의 확장으로 계속해 강세를 보이고 있다. 함께 기존 빅2로 꼽히는 아모레퍼시픽 또한 2023년 생산금액 약 3조 2천억원으로 점유율 22.3%를 차지해 고성장 스킨케어로 중국, 미국 등 주요 시장에 성 장을 이끌었다.

해당 보고서에 따르면 LG생활건강, 아모레퍼시픽, 코스맥스 등 상위 10대 기업 생산액 점유율은 21년도 69.3%에서 23년도 55.5로 꾸준한 하락세를 보이고 있다. 이러한 감소는 올린뷰티, 비건 제품, 개인 맞춤형 스킨케어 솔루션과 같은 틈새 시장을 공략하는 소규모 인디 브랜드들의 영향력이 커지고 있음을 나타낸다. 화장품은 한국의 중소기업 수출 동력 1위로 수입년간 대기업이 뛰어들지 못한 시장 유럽, 미국 등에서 수출 성장을 보여준다.



24년 중소벤처기업의 '2023년 중소기업 수출동향'에 따르면 화장품은 54억달러로 수출동향 1위를 차지하며, 중소기업 수출동향 1위로 2년만에 복귀하였다. 또한 중소기업 온라인 수출 1위도 화장품이 차지했다. 중국 소비자들과 소비 문화, 애용소비 운동 등 수출이 강소하는 모습을 보였으나, 미국일본베트남 등의 수출국이 다변화되어 중소기업의 화장품 수출액은 연간 역대 최대 실적을 기록했다고 분석했다. 국내 ODM 산업 또한 수출 호조의 수혜를 누리고 있다. ODM 분야의 주요 기업인 코스맥스는 2022년 생산금액 807억원으로 0.6% 점유율에서 2023년 생산금액 1,164억원으로 0.8%로 12위에서 3계단 상승한 상위 9위 업체가 되었다. ODM 기업은 생산 인프라를 갖추지 못한 중소 인디 브랜드에도 화장품을 개별 시장 접근성을 갖추게 한다는 의미에서 화장품 산업의 중소 기업 성장세를 또한 엿볼 수 있다.

외부 문서와 코사인 유사도 비교 결과 - TopK 수정

```
PS C:\Users\LG> python rank_full_doc2doc_strict.py 'C:\Users\LG\dh1qnqhrhtj_chunk_embeddings.npy'
```

```
Content-sim (PCA-debiased & strict) - Top-3 for 'C:\Users\LG\dh1qnqhrhtj_chunk_embeddings.npy':
```

```
1. medicuresolutions DocSim=0.2104 PctMean_Q→C=0.2199 PctMean_C→Q=0.2208 Trim_Q→C=0.2020 Trim_C→Q=0.1987 Cov85_Q→C=0.0% Cov85_C→Q=0.0% Cov90_Q→C=0.0% Cov90_C→Q=0.0% [Q=341, C=257]
2. neobiosense DocSim=0.2098 PctMean_Q→C=0.2220 PctMean_C→Q=0.2168 Trim_Q→C=0.2039 Trim_C→Q=0.1967 Cov85_Q→C=0.0% Cov85_C→Q=0.0% Cov90_Q→C=0.0% Cov90_C→Q=0.0% [Q=341, C=254]
3. nextfintech DocSim=0.2087 PctMean_Q→C=0.2189 PctMean_C→Q=0.2174 Trim_Q→C=0.2009 Trim_C→Q=0.1974 Cov85_Q→C=0.0% Cov85_C→Q=0.0% Cov90_Q→C=0.0% Cov90_C→Q=0.0% [Q=341, C=259]
```

항목	의미	해석 방식
DocSim	전체 문서 간 평균 코사인 유사도 (Dense 벡터 or Hybrid 점수)	값이 높을수록 문서 수준에서 의미적으로 더 유사함
PctMean_Q→C	Query(질문 문서)의 모든 청크가 Comparison 문서의 청크들과 비교될 때 평균 유사도	“질문 문서의 각 문장이 상대 문서의 어느 부분과 얼마나 비슷한가”
PctMean_C→Q	반대 방향: Comparison 문서의 각 청크가 Query의 청크들과 비교될 때 평균 유사도	“비교 문서의 내용이 질문 문서 어디와 얼마나 비슷한가”
Trim_Q→C / Trim_C→Q	이상치(너무 낮거나 높은 청크)를 잘라낸 뒤 평균	의미 없는 잡음 제외 후 실질적인 유사도만 평가한 값
Cov85 / Cov90 (Coverage)	“0.85(혹은 0.90) 이상으로 일치하는 청크 쌍의 비율”	두 문서에서 <i>아주 강하게 유사한 부분이 얼마나 존재하는가</i>
[Q=341, C=257]	Query 문서는 341개 청크, Comparison 문서는 257개 청크로 분할됨	문서 길이 및 비교 단위 수를 의미

진행 중인 일



BM25 벡터스토어 연결

코사인유사도 코드
파라미터 값 정하기

외부 문서 생성

진행 중인 일

앞으로 할 일




BM25로 단어 유사도 판별 코드

코사인 유사도 + 단어유사도
판별 LLM

산학협력프로젝트
결과보고서 작성

앞으로 할 일



감사합니다

