


융합보안 프리캡스톤 디자인

AI 기반 문서 유사도 판별 시스템



목차

table of contents



파이프라인

최종 로직



여러 피드백을 수용해 최종 발표때까지 구현할 프로젝트 파이프라인

기밀 문서 (사전에 구현)	외부 문서 (업로드 시)	유출 시도 시 로직
문서 파서 	문서 파서 	(1)임베딩 파일끼리 코사인 유사도 판별 
문서 청킹 	문서 청킹 	(2)BM25를 이용해 단어 유사도 판별 
청킹된 json 임베딩 	청킹된 json 임베딩 	(1)과 (2)에 대한 Hybrid 유사도
BM25에 대한 용어집에 로드 	BM25에 대한 용어집에 새로 업로드 	LLM이 동적 분석을 통해 판정

이번주 한 일

11월 6일 ~ 11월 12일



한 일 목록

단어 유사도 결과 코드

외부 문서로 테스트

판넬, 책자 제작

단어 유사도 결과

```
compare.py > ...
1  import json, re, argparse
2  from pathlib import Path
3  from collections import Counter, defaultdict
4  from qdrant_client import QdrantClient, models
5
6  # ----- tokenizers -----
7  _KOREAN_RE = re.compile(r"[가-힣]")
8
9  def _tok_simple(s: str):
10     s = re.sub(r"[^0-9a-zA-Z가-힣]+", " ", s)
11     return [t for t in s.strip().split() if t]
12
13  def _tok_okt(s: str):
14     from konlpy.tag import Okt
15     okt = Okt()
16     return [t for t in okt.nouns(s) if len(t) >= 2]
17
18  def _tok_mecab(s: str):
19     from mecab import MeCab
20     m = MeCab()
21     return [t for t in m.nouns(s) if len(t) >= 2]
22
23  def make_tokenizer(name: str):
24     name = (name or "simple").lower()
25     base = _tok_simple
26     if name == "okt": base = _tok_okt
27     if name == "mecab": base = _tok_mecab
```

- BM25 용어집을 활용한
단어 유사도 코드 제작

이번주 한 일

11월 6일 ~ 11월 12일



한 일 목록

단어 유사도 결과 코드

외부 문서로 테스트

판넬, 책자 제작

외부 문서

- 배터리 (전기차) 관련 문서를 외부용으로 제작

"산업 패러다임의 거대한 전환",
"전기차(EV) 및 배터리 산업, 단순한 기술 혁신을 넘어선 핵심 동력으로 부상",
"내연기관 중심에서 전동화(Electrification)로의 이동 가속화",
"에너지 전환 및 지속 가능한 미래 성장의 중심축으로 자리매김",
"금융회사의 새로운 기회와 도전",
"전례 없는 규모의 산업 재편 과정에서 발생하는 신규 금융 수요 포착",
"기술, 정책, 시장의 급변에 따른 잠재적 리스크 관리의 중요성 동시 대두",
"시장 선도를 위한 금융회사의 전략적 의사결정 및 선제적 대응 요구",
"본 보고서의 목적",
"전기차-배터리 시장의 최신 동향 및 핵심 이슈 분석",
"글로벌 공급망, 기술 혁신, 주요국 정책 변화 집중 조망",
"산업 변화가 금융 시장에 미치는 영향 및 비즈니스 기회 전망",
"금융회사의 구체적인 대응 전략 및 전략적 시사점(Implication) 제시 II. 글로벌 전기차(EV) 시장 현황 및 전망",
"글로벌 EV 시장, '캐즘' 우려 속 고성장세 지속",
"2024년 기준, 글로벌 전기차 시장은 연평균 20% 내외의 견조한 성장세 유지",
"단기적 성장 둔화(캐즘) 우려 상존하나, 장기적 전동화 방향성 불변",
"주요국의 강력한 탄소중립 정책, 소비자 인식 개선, 기술 발전이 성장을 견인",
"주요 권역별 시장 동향",
"(중국)",
"세계 최대 전기차 시장 지위 공고",
"BYD, 지리(Geely) 등 자국 브랜드를 중심으로 내수 및 수출 시장 동시",
"중저가 LFP 배터리 기반 가격 경쟁력 확보, 글로벌 시장 공략 가속",
"(유럽)",
"강력한 환경 규제(Euro 7, CBAM) 및 보조금 정책 기반의 빠른 전환",
"폭스바겐, 스텔란티스 등 전통 OEM의 전동화 전환 가속",
"역내 배터리 공급망 구축(배터리 여권 등) 노력 병행",
"(북미)",
"테슬라(Tesla)의 견고한 시장 지배력 지속",
"GM, 포드 등 'Legacy Auto' 기업들의 전기차 라인업 강화로 경쟁 심화",
"미국 인플레이션 감축법(IRA) 발효로 자국 중심 공급망 재편 본격화",
"주요 시장 트렌드 변화",

이번주 한 일

11월 6일 ~ 11월 12일



한 일 목록

단어 유사도 결과 코드

외부 문서로 테스트

판넬, 책자 제작

테스트 결과_코사인

Content_sim (PCA-debiased & strict) - Top-10 for 'C:\Users\LG\dh1qn_v5_chunk_embeddings.npy':

1. zonaibattery	DocSim=0.2409	PctMean_Q→C=0.2865	PctMean_C→Q=0.2196	Trim_Q→C=0.2636	Trim_C→Q=0.1939	Cov85_Q→C=0.0%	Cov85_C→Q=0.0%	Cov90_Q→C=0.0%	Cov90_C→Q=0.0%	[Q=190, C=401]
2. futurebattery	DocSim=0.2212	PctMean_Q→C=0.2446	PctMean_C→Q=0.2168	Trim_Q→C=0.2252	Trim_C→Q=0.1982	Cov85_Q→C=0.0%	Cov85_C→Q=0.0%	Cov90_Q→C=0.0%	Cov90_C→Q=0.0%	[Q=190, C=241]
3. mundopharm	DocSim=0.1996	PctMean_Q→C=0.2251	PctMean_C→Q=0.1903	Trim_Q→C=0.2079	Trim_C→Q=0.1751	Cov85_Q→C=0.0%	Cov85_C→Q=0.0%	Cov90_Q→C=0.0%	Cov90_C→Q=0.0%	[Q=190, C=406]
4. nextfintech	DocSim=0.1991	PctMean_Q→C=0.2145	PctMean_C→Q=0.2011	Trim_Q→C=0.1977	Trim_C→Q=0.1831	Cov85_Q→C=0.0%	Cov85_C→Q=0.0%	Cov90_Q→C=0.0%	Cov90_C→Q=0.0%	[Q=190, C=259]
5. raumcivil	DocSim=0.1974	PctMean_Q→C=0.2243	PctMean_C→Q=0.1873	Trim_Q→C=0.2067	Trim_C→Q=0.1712	Cov85_Q→C=0.0%	Cov85_C→Q=0.0%	Cov90_Q→C=0.0%	Cov90_C→Q=0.0%	[Q=190, C=396]
6. nunufactory	DocSim=0.1960	PctMean_Q→C=0.2233	PctMean_C→Q=0.1853	Trim_Q→C=0.2048	Trim_C→Q=0.1708	Cov85_Q→C=0.0%	Cov85_C→Q=0.0%	Cov90_Q→C=0.0%	Cov90_C→Q=0.0%	[Q=190, C=410]
7. ivanfarm	DocSim=0.1959	PctMean_Q→C=0.2200	PctMean_C→Q=0.1859	Trim_Q→C=0.2054	Trim_C→Q=0.1725	Cov85_Q→C=0.0%	Cov85_C→Q=0.0%	Cov90_Q→C=0.0%	Cov90_C→Q=0.0%	[Q=190, C=389]
8. leonaconstruction	DocSim=0.1959	PctMean_Q→C=0.2221	PctMean_C→Q=0.1852	Trim_Q→C=0.2054	Trim_C→Q=0.1711	Cov85_Q→C=0.0%	Cov85_C→Q=0.0%	Cov90_Q→C=0.0%	Cov90_C→Q=0.0%	[Q=190, C=413]
9. hydrogentech	DocSim=0.1959	PctMean_Q→C=0.2136	PctMean_C→Q=0.1948	Trim_Q→C=0.1966	Trim_C→Q=0.1787	Cov85_Q→C=0.0%	Cov85_C→Q=0.0%	Cov90_Q→C=0.0%	Cov90_C→Q=0.0%	[Q=190, C=273]
10. solarwave	DocSim=0.1954	PctMean_Q→C=0.2120	PctMean_C→Q=0.1960	Trim_Q→C=0.1945	Trim_C→Q=0.1791	Cov85_Q→C=0.0%	Cov85_C→Q=0.0%	Cov90_Q→C=0.0%	Cov90_C→Q=0.0%	[Q=190, C=281]

이번주 한 일

11월 6일 ~ 11월 12일



한 일 목록

단어 유사도 결과 코드

외부 문서로 테스트

판넬, 책자 제작

테스트 결과_단어

```
[문서 Top-10] (mode=topMsum, M=5, raw score)
2100.477325 조나우배터리 투자 분석 보고서
2055.814972 퓨처배터리 투자 분석 보고서
1397.725494 그린퓨처 투자 분석 보고서
1383.715454 넥스트핀테크 투자 분석 보고서
1122.275192 사이온모터스 투자 분석 보고서
1098.773926 플렉스웨이브페이 투자 분석 보고서
1018.939285 하이드로젠텍 투자 분석 보고서
1001.395721 네오바이오센스 투자 분석 보고서
995.074158 라움토목 투자 보고서
982.754990 잔나원드테크 투자 분석 보고서
```

이번주 한 일

11월 6일 ~ 11월 12일




한 일 목록

단어 유사도 결과 코드

외부 문서로 테스트

책자, 판넬 제작

책자 제작



이번주 한 일

11월 6일 ~ 11월 12일



한 일 목록

단어 유사도 결과 코드

외부 문서로 테스트

책자, 판넬 제작

책자 제작

일련번호0000

이 문서, 어디서 본 듯한데..
유출 신호?

소속한성대학교 융합보안학과

구성원한동균 / 유예지

지도교수이강신 교수님

주제: AI 기반 유사 문서 검증 시스템
부제: 투자회사 문서 관리 특화 모델

프로젝트 목표: 투자회사 기밀 문서(투심보고서)와 이후 업로드 문서간의 유사도 분석을 통해 내부 정보 유출 가능성을 조기 탐지하는 것

1서론

1-1추진 배경

투자 업계에서 숫자 하나, 그래프 한 장은 회사의 핵심 기밀이자 시장의 판도를 바꿀 수 있는 민감한 정보입니다. 이러한 정보가 무실로 외부로 유출될 경우, 단순히 기업의 손실을 넘어 사회 전체에 큰 파급력을 일으키는 금융 범죄로 이어질 수 있습니다. 최근 발생한 SG증권발 추가 폭락 사태나 CJ ENM의 추가조작 사건들은 미공개 정보가 악의적으로 이용되었을 때, 투자자들에게 막대한 피해를 입히고 시장의 신뢰를 무너트린 대표적인 사례입니다. 이러한 사건들은 내부 정보의 유출과 오남용이 단순히 기업 내부의 문제를 넘어 사회적 재난으로 번질 수 있음을 분명히 보여줍니다.

1-2프로젝트 목적

본 프로젝트의 목적은 투자회사 내부의 핵심 기밀 자료인 투심보고서를 체계적으로 관리하고 이후 업로드되는 문서와의 AI 기반 유사도 비교 분석을 통해 내부 정보 유출 가능성을 조기에 탐지하는 시스템을 구축하는 것에 있습니다. 앞서 추진 배경에서 언급한 바와 같이 미공개 정보 유출 사건들은 시장 교란으로 직결될 수 있음을 보여주고 있습니다. 이에 본 프로젝트는 기존 DLP 시스템에서 활용되는 의미 기반 유사도 분석 기법을 기반으로 하되 LLM을 추가적으로 적용하여 문서 간 의미적 맥락을 종합적으로 해석하고 유사도 점수를 동적으로 보정하는 구조를 도입하였습니다. 이를 통해 단순한 수치 계산에 그치지 않고 문서의 실제 의미적 유사성을 반영하는 정교한 탐지 체계를 구현하고자 합니다.

1-3기존 DLP와의 차별점

기존의 DLP 시스템은 주로 문자열 패턴, 키워드, 정규식 등을 기반으로 동작하며 문서 내 특정 단어나 구문이 일치할 경우 이를 유출 위험으로 판단한다. 이러한 방식은 문맥적 의미나 문장 구조의 유사성을 반영하지 못하기 때문에, 실제 내용이 비슷하지만 단어 표현이 달라진 문서는 탐지하지 못하는 한계가 있다.

본 프로젝트에서 제안하는 시스템은 이러한 한계를 극복하기 위해 BM25 기반의 최소 표현과 교사인 유사도 기반의 밀집 표현을 함께 활용하였다. 이 두 방식의 결과를 결합함으로써 문서 간의 의미적 유사도와 통계적 유사도를 동시에 반영할 수 있다. 또한, LLM을 통한 학습 및 보정 과정을 추가하여 단순한 수치 비교를 넘어 의미 기반의 정밀한 유사도 판별이 가능하도록 하였다. 특히 본 시스템은 투자회사 내부 문서와 투심보고서의 특수한 문제-구조를 반영한 맞춤형 모델로 설계되었다. 이 점에서 기존의 일반적인 DLP 모델과 달리, 도메인 특화형 탐지 체계라는 뚜렷한 차별성을 지닌다.

요약하면, 본 시스템은 "의미 기반 + 투자사 전용"이라는 이중 구조를 통해 기존 DLP와의 차별점을 띄고 있다.

아래 표는 기존 DLP 시스템과 본 시스템의 주요 차이점을 비교한 것이다.

구분	과거 DLP 시스템	현재 DLP 시스템	본 프로젝트 시스템
탐지 방식	키워드, 정규식 기반	BM25, 교사인 등 Hybrid 점수 계산	Hybrid 점수를 LLM이 통적으로 조정
판단 구조	규칙 기반 단순 매칭	정적 가중치, 평균 계산	LLM이 통합 점수 보정
의미 이해 수준	낮음 (단어 일치 중심)	중간 (문장 수준 의미 반영)	중간 이상 (문장 패턴 기반 의미 보정)
정확도 개선 방식	수동 규칙 보정	통계적 가중치 적용	LLM 기반 점수 보정 및 상황별 최적화
도메인 적합성	범용 문서 위주	산업 전반 적용	투자사, 투심보고서 특화 모델

이번주 한 일

11월 6일 ~ 11월 12일



한 일 목록

단어 유사도 결과 코드

외부 문서로 테스트

책자, 판넬 제작

판넬 제작

2025 한성 SW중심대학 페스티벌

이 문서, 어디서 본 듯한데.. 유출 신호?

과목명: 융합보안 프리캡스톤 디자인
한동균(융합보안학과), 유예지(융합보안학과)
지도교수: 김승천 교수, 이강신 교수
산업체 멘토: 소만사 김정환 팀장

추진배경

투자 업계의 숫자 하나, 그래프 한 장은 기업의 핵심 기밀이자 시장을 뒤흔들 수 있는 민감 정보입니다. 이러한 정보가 유출될 경우 단순한 손실을 넘어 금융 범죄와 광범위한 사회적 파급으로 이어집니다. SG증권 사태와 CJ ENM 주가조작 사례는 미공개 정보 악용이 투자자 피해와 시장 신뢰 붕괴를 초래한다는 사실을 분명히 보여줍니다.

프로젝트 목적

투자회사 내부의 핵심 기밀 자료인 투심보고서를 이후 업로드되는 문서와의 AI 기반 유사도 비교 분석을 통해 내부 정보 유출을 탐지하는 시스템을 구축하는 것에 있습니다. 기존 DLP 시스템에 LLM을 추가적으로 적용하여 문서 간 의미적 맥락을 종합적으로 해석하고 유사도 점수를 동적으로 보정하는 구조를 도입했습니다. 이를 통해 단순한 수치 계산에 그치지 않고 문서의 실제 의미적 유사성을 반영하는 탐지 체계를 구현하고자 합니다.


기존 DLP와의 차별점

구분	과거 DLP 시스템	현재 DLP 시스템	본 프로젝트 시스템
탐지 방식	키워드, 정규식 기반	PMML, 코사인 등 유사성 점수 계산	Hybrid 점수를 LLM이 동적으로 조정
판단 구조	규칙 기반 단순 해명	정적 가중치, 룰 기반 계산	LLM이 판단 점수 보정
오차 이해 수준	낮음 (단어 일치 중심)	중간 (문장 수준 의미 반영)	높은 이상 (문장 의미 기반 오차 보정)
정확도 계산 방식	수동 규칙 보정	통계적 가중치 적용	LLM 기반 점수 보정 및 상황별 최적화
도메인 적용성	범용 문서 위주	산업 전반 적용	투자사, 투심보고서 특화 모델

본 시스템은 의미 기반 + 투자사 전용이라는 이중 구조를 통해 기존 DLP와의 차별점을 띄고 있다.

왼쪽의 표는 기존 DLP 시스템과 본 시스템의 차이점을 비교한 것이다.

구조 및 주요 적용 기술



1. 임베딩: bge-m3-ko
2. bm25: rank bm25
3. 벡터스토어: qdrant
4. 협업도구: github, notion

결론

투자회사 특화 AI 유사 문서 검출 시스템을 구축하여, 임베딩(코사인)과 BM25를 병렬로 산출하고 LLM 하이브리드로 통합해 정확도·견고성을 확보했다. 프로그램의 성능을 검증하기 위해 테스트를 수행하였다. 전기차 배터리 관련 문서를 업로드하여 분석한 결과, 코사인 유사도와 BM25 단어 유사도 모두에서 상위 3개 문서가 모두 배터리 관련 문서로 판별되었다. 이로써 단순 키워드 매칭을 넘어 문맥적 의미 유사성과 도메인 용어 분포를 함께 고려하는 시스템을 개발할 수 있었다.

```
[문서 Top-10] (mode=topMsum, M=5, raw score)
2100.477325  조나우배터리 투자 분석 보고서
2055.814972  퓨처배터리 투자 분석 보고서
1397.725494  그린퓨처 투자 분석 보고서
```

진행 중인 일



서버 연결

코사인유사도 코드
파라미터 값 정하기

전체 LLM 코드

진행 중인 일

앞으로 할 일



외부 문서 다양하게 제작

LLM 판사 프롬프트

산학협력프로젝트
결과보고서 작성

앞으로 할 일



감사합니다

