

융합보안 프리캡스톤 디자인

AI 기반 문서 유사도 판별 시스템





이번주 한 일

01

BM25
정규화

02

결과 수정

bm25 정규화

11월 20일 ~ 12월 3일



bm25_doc_max.json

```
for doc_id in sorted(all_doc_ids):
    bm25_raw = bm25_scores.get(doc_id, 0.0)
    cos_raw = cosine_scores.get(doc_id, 0.0)

    # --- BM25 정규화: 문서별 최대값으로 나누기 ---
    bm25_doc_max = bm25_max_table.get(doc_id, 0.0)
    if bm25_doc_max > 0.0:
        bm25_rel = bm25_raw / bm25_doc_max # 0~1, 동일 문서면 1에 가까워짐
    else:
        bm25_rel = 0.0

    bm25_nct = bm25_rel * 100.0
```

```
"file": "그린퓨처_투자보고서.docx",
"best_score": 1973.4460144042969,
"best_doc_id": "그린퓨처_투자보고서",
"top_matches": [
```

```
'file': "네오바이센스_투자보고서.docx",
'best_score': 2838.302490234375,
'best_doc_id': "네오바이센스_투자보고서",
'top_matches': [
```

```
'file': "넥서스모터스_투자보고서.docx",
'best_score': 2576.3264770507812,
'best_doc_id': "넥서스모터스_투자보고서",
'top_matches': [
```

결과 수정

11월 20일 ~ 12월 3일



하이브리드 가중치 설정

```
# 하이브리드 가중치  
BM25_WEIGHT = 0.6  
COSINE_WEIGHT = 0.4
```


결과 수정

11월 20일 ~ 12월 3일



```
(pz1) PS C:\Users\gkse\hansung\HS> uv run python rag_pipeline_v4.py query --query_file "C:/Users/gkse/hansung/HS/query_docs/외부의료.hwp"
--- 2. 쿼리 시작: 외부의료.hwp ---
[Parse] 외부의료.hwp (type: .hwp)
[Query] 187개 청크 생성.
[Query-Dense] 코사인 유사도 검색 중...
[Query-Dense] 30개 문서 결과.
[Query-Sparse] BM25 유사도 검색 중...
[Query-Sparse] 30개 문서 결과.
--- ✅ 쿼리 및 하이브리드 스코어 계산 완료. ---

--- 요약: 하이브리드 상위 10개 문서 ---
1. 문도제약_투자보고서 Hybrid= 42.53% (BM25=1384.8, BM25%= 53.9%, Cosine=0.2539 / 25.4%)
2. 네오바이센스_투자보고서 Hybrid= 36.68% (BM25=1667.1, BM25%= 44.9%, Cosine=0.2435 / 24.4%)
3. 오로라솔루션즈 투자 보고서 Hybrid= 34.24% (BM25=1177.1, BM25%= 41.1%, Cosine=0.2401 / 24.0%)
4. 메디큐어솔루션즈_투자보고서 Hybrid= 32.54% (BM25=1273.6, BM25%= 38.3%, Cosine=0.2383 / 23.8%)
5. 넥스트핀테크_투자보고서 Hybrid= 30.06% (BM25=1058.3, BM25%= 35.9%, Cosine=0.2126 / 21.3%)
6. 쉬엔의료 투자 보고서 Hybrid= 29.91% (BM25=1095.9, BM25%= 33.7%, Cosine=0.2419 / 24.2%)
7. 누누팩토리_투자보고서 Hybrid= 29.73% (BM25=887.3, BM25%= 36.0%, Cosine=0.2034 / 20.3%)
8. 시그마게임즈 투자 보고서 Hybrid= 29.12% (BM25=838.4, BM25%= 34.3%, Cosine=0.2138 / 21.4%)
9. 그린퓨처_투자보고서 Hybrid= 28.76% (BM25=812.7, BM25%= 34.6%, Cosine=0.1993 / 19.9%)
10. 라움토목_투자보고서 Hybrid= 28.49% (BM25=834.9, BM25%= 34.2%, Cosine=0.1997 / 20.0%)
```

결과 수정

11월 20일 ~ 12월 3일



```
(pz1) PS C:\Users\gkse\hansung\HS> uv run python rag_pipeline_v4.py query --query_file "C:/Users/gkse/hansung/HS/query_docs/외부의료.hwp"
--- 2. 쿼리 시작: 외부의료.hwp ---
[Parse] 외부의료.hwp (type: .hwp)
[Query] 187개 청크 생성.
[Query-Dense] 코사인 유사도 검색 중...
[Query-Dense] 30개 문서 결과.
[Query-Sparse] BM25 유사도 검색 중...
[Query-Sparse] 30개 문서 결과.
--- ✅ 쿼리 및 하이브리드 스코어 계산 완료. ---

--- 요약: 하이브리드 상위 10개 문서 ---
1. 문도제약_투자보고서 Hybrid= 42.53% (BM25=1384.8, BM25%= 53.9%, Cosine=0.2539 / 25.4%)
2. 네오바이센스_투자보고서 Hybrid= 36.68% (BM25=1667.1, BM25%= 44.9%, Cosine=0.2435 / 24.4%)
3. 오로라솔루션즈 투자 보고서 Hybrid= 34.24% (BM25=1177.1, BM25%= 41.1%, Cosine=0.2401 / 24.0%)
4. 메디큐어솔루션즈_투자보고서 Hybrid= 32.54% (BM25=1273.6, BM25%= 38.3%, Cosine=0.2383 / 23.8%)
5. 벅스트핀테크_투자보고서 Hybrid= 30.06% (BM25=1058.3, BM25%= 35.9%, Cosine=0.2126 / 21.3%)
6. 쉬엔의료 투자 보고서 Hybrid= 29.91% (BM25=1095.9, BM25%= 33.7%, Cosine=0.2419 / 24.2%)
7. 누누팩토리_투자보고서 Hybrid= 29.73% (BM25=887.3, BM25%= 36.0%, Cosine=0.2034 / 20.3%)
8. 시그마게임즈 투자 보고서 Hybrid= 29.12% (BM25=838.4, BM25%= 34.3%, Cosine=0.2138 / 21.4%)
9. 그린퓨처_투자보고서 Hybrid= 28.76% (BM25=812.7, BM25%= 34.6%, Cosine=0.1993 / 19.9%)
10. 라움토목_투자보고서 Hybrid= 28.49% (BM25=834.9, BM25%= 34.2%, Cosine=0.1997 / 20.0%)
```

결과 수정

11월 20일 ~ 12월 3일



```
"query_document": "회의록_1",
"top_matches": [
  {
    "doc_id": "누누팩토리_투자보고서",
    "hybrid_pct": 48.3782363053686,
    "bm25_pct": 42.43714413982739,
    "cosine_pct": 57.28987455368042,
    "sentence_matches": [
      {
        "query_sentence": "\"현재 미국 IoT 업체와 게이트웨이 관련 특허 분쟁이 2024년에 제소된 상태이고, 이 건은 회사 내부에서도 IPO 심사 리스크로 인식하고 있습니다.\"",
        "matched_sentence": "\"특허·법적 분쟁 : 미국 IoT 업체와 게이트웨이 특허 분쟁 진행 중(2024년 제소), IPO 심사 리스크\"",
        "cosine_score": 0.8991056680679321
      },
      {
        "query_sentence": "\"기술적으로는 센서 SoC 자체 설계 역량과 게이트웨이 모듈 특허 12건 정도 포트폴리오가 있고, 스마트팩토리·스마트시티 쪽 수요 확대 수혜를 기대하고 있습니다\"",
        "matched_sentence": "\"기술 경쟁력 : 센서 SoC 자체 설계, 게이트웨이 모듈 12건 특허 포트폴리오 보유\"",
        "cosine_score": 0.8538621068000793
      },
      {
        "query_sentence": "\"또 일부 제품군에서 전파인증·보안인증 갱신이 지연되면서 납기 차질 사례가 이미 발생했고, 향후 규제 강화 시 연간 인증 비용 증가와 출시 지연 가능성이 있습니다\"",
        "matched_sentence": "\"보안 인증 리스크 : 일부 제품군 전파인증/보안인증 갱신 지연으로 납기 차질 발생..\"",
        "cosine_score": 0.8336813449859619
      },
      {
        "query_sentence": "\"2025년 기준 매출 42억, 영업이익 5.8억 정도입니다\"",
        "matched_sentence": "\"사업 규모 : 2025년 매출 42억 원, 영업이익 5.8억 원, 임직원 189명\"",
        "cosine_score": 0.8313286304473877
      },
      {
        "query_sentence": "\"회사 자체 매출 전망은 2025년 42억에서 2030년 116억까지, 내부 기준으로는 CAGR 22.6% 시나리오를 베이스로 두고 있습니다\"",
        "matched_sentence": "\"매출 전망: 2025년 42억 원 → 2030년 116억 원 (CAGR 약 22.6%)\"",
        "cosine_score": 0.8105320334434509
      }
    ]
  }
]
```

결과 수정

11월 20일 ~ 12월 3일



```
"query_document": "회의록_1",  
"top_matches": [  
  {  
    "doc_id": "누누팩토리_투자보고서",  
    "hybrid_pct": 48.3782363053686,  
    "bm25_pct": 42.43714413982739,  
    "cosine_pct": 57.28987455368042,
```

```
"query_sentence": "\"현재 미국 IoT 업체와 게이트웨이 관련 특허 분쟁이 2024년에 제소된 상태이고, 이 건은 회사 내부에서도 IPO 심사 리스크로 인식하고 있습니다.\"",  
"matched_sentence": "\"특허·법적 분쟁 : 미국 IoT 업체와 게이트웨이 특허 분쟁 진행 중(2024년 제소), IPO 심사 리스크\",  
"cosine_score": 0.8991056680679321
```

```
  },  
  {  
    "query_sentence": "기술적으로는 센서 SoC 자체 설계 역량과 게이트웨이 모듈 특허 12건 정도 포트폴리오가 있고, 스마트팩토리·스마트시티 쪽 수요 확대 수혜를 기대하고 있습  
    "matched_sentence": "○기술 경쟁력 : 센서 SoC 자체 설계, 게이트웨이 모듈 12건 특허 포트폴리오 보유",  
    "cosine_score": 0.8538621068000793  
  },  
  {  
    "query_sentence": "또 일부 제품군에서 전파인증·보안인증 갱신이 지연되면서 납기 차질 사례가 이미 발생했고, 향후 규제 강화 시 연간 인증 비용 증가와 출시 지연 가능성이  
    "matched_sentence": "\"보안 인증 리스크 : 일부 제품군 전파인증/보안인증 갱신 지연으로 납기 차질 발생..",  
    "cosine_score": 0.8336813449859619  
  },  
  {  
    "query_sentence": "2025년 기준 매출 42억, 영업이익 5.8억 정도입니다.",  
    "matched_sentence": "○사업 규모 : 2025년 매출 42억 원, 영업이익 5.8억 원, 임직원 189명",  
    "cosine_score": 0.8313286304473877  
  },  
  {  
    "query_sentence": "회사 자체 매출 전망은 2025년 42억에서 2030년 116억까지, 내부 기준으로는 CAGR 22.6% 시나리오를 베이스로 두고 있습니다.""",  
    "matched_sentence": "○매출 전망: 2025년 42억 원 → 2030년 116억 원 (CAGR 약 22.6%)",  
    "cosine_score": 0.8105320334434509  
  }  
]
```


결과 수정

11월 20일 ~ 12월 3일



```
def summarize_with_llm_local(payload: Dict) -> str:
    """
    payload를 기반으로 로컬 LLM을 호출해
    GitHub 마크다운 형식의 유사도 분석 리포트를 생성한다.
    """
    json_block = json.dumps(payload, ensure_ascii=False, indent=2)

    prompt = (
        "다음 JSON은 쿼리 문서와 상위 3개 문서의 문장 단위 매칭 결과입니다.\n"
        "이 정보를 이용해서, 아래 형식에 맞는 **GitHub 마크다운 문서**를 한국어로만 작성하세요.\n\n"
        "# 문서 유사도 분석 리포트\n\n"
        "## 1. 개요\n"
        "- 분석 대상: 쿼리 문서 1개와 상위 3개 유사 문서\n"
        "- 점수 기준: BM25, 코사인 유사도, 하이브리드 점수\n\n"
        "## 2. 문서 요약\n"
        "아래 형식을 반드시 지켜주세요.\n"
        "각 문서는 1~2문장으로 요약합니다.\n\n"
        "- 쿼리 문서(파일명: ...): ...\n"
        "- 내부 문서1(파일명: ...): ...\n"
        "- 내부 문서2(파일명: ...): ...\n"
        "- 내부 문서3(파일명: ...): ...\n\n"
        "요약 시 다음 내용을 포함하려고 노력하세요.\n"
        "- 문서의 성격 (예: 투자보고서, 계약서, 제안서, 내부검토문서 등)\n"
        "- 핵심 의사결정이나 결론 (예: 투자 여부, 승인/반려, 리스크 요약 등)\n\n"
        "## 3. 상위 문서 점수 요약\n"
        "- 표를 사용하여 각 상위 문서의 BM25%, 코사인%, 하이브리드%를 정리하세요.\n"
        "- 표 헤더 예시:\n"
        "  | 순위 | 문서명 | BM25(%) | 코사인(%) | 하이브리드(%) |\n\n"
        "## 4. 유사 문장 쌍 상세\n"
        "각 상위 문서별로 아래 형식을 반복해서 작성하세요. (문서당 최대 5개 쌍)\n"
        "### 문서명: 예시_문서명\n"
        "1. **쿼리 문장** \n"
        "   \"...\" \n"
        "   **상대 문서 문장** \n"
        "   \"...\" \n"
        "   **코사인 유사도**: 0.xx\n\n"
        "2. ...\n"
        "작성 규칙:\n"
        "- 유사도 점수는 cosine_score를 사용하고, 내림차순(큰 값 → 작은 값)으로 정렬된 것처럼 표현하세요.\n"
        "- 의미적으로 많이 비슷해 보이는 문장(0.7 이상)은 꼭 포함하세요.\n"
        "- 전체 출력은 하나의 완전한 마크다운 문서가 되도록 작성하세요.\n"
        "- JSON 원문은 마크다운 문서에 다시 넣지 마세요.\n\n"
        "아래는 참고할 JSON 데이터입니다.\n\n"
        f"{json_block}\n"
```




문서 유사도 분석 리포트

1. 개요

- 분석 대상: 쿼리 문서 1개와 상위 3개 유사 문서
- 점수 기준: BM25, 코사인 유사도, 하이브리드 점수

2. 문서 요약

- 아래 형식을 반드시 지켜주세요.
- 각 문서는 1~2문장으로 요약합니다.
- 쿼리 문서(파일명: 회의록_1): 미국 IoT 업체와 게이트웨이 관련 특허 분쟁, IPO 심사 리스크, 센서 SoC 설계 역량 및 게이트웨이 모듈 특허 포트폴리오 등을 포함한 기술 경쟁력, 2025년과 2030년의 매출 전망을 제시하고 있습니다.
- 문서1(파일명: 누누팩토리_투자보고서): 투자 여부에 대한 권고, 특허 분쟁 리스크와 보안 인증 리스크, 사업 규모 및 매출 전망, IPO 심사 리스크를 포함하고 있습니다.
- 문서2(파일명: 라움토목_투자보고서): 투자 여부, IRR과 MOIC 등의 수익성 지표, 매출 및 영업이익 전망, 임직원 규모 등을 요약하고 있습니다.
- 문서3(파일명: 시그마게임즈 투자 보고서): 투자 권고와 함께 임직원 리텐션 프로그램, 매출과 영업이익 증가 전망, IRR 및 MOIC 등의 수익성 분석을 포함하고 있습니다.

3. 상위 문서 점수 요약

순위	문서명	BM25(%)	코사인(%)	하이브리드(%)
1	누누팩토리_투자보고서	42.44	57.29	48.38
2	라움토목_투자보고서	27.26	52.12	37.20
3	시그마게임즈 투자 보고서	24.56	51.81	35.46

4. 유사 문장 쌍 상세

문서명: 누누팩토리_투자보고서

- 쿼리 문장
"현재 미국 IoT 업체와 게이트웨이 관련 특허 분쟁이 2024년에 제소된 상태이고, 이
것은 회사 내부에서도 IPO 심사 리스크로 인식하고 있습니다."

4. 유사 문장 쌍 상세

문서명: 누누팩토리_투자보고서

- 쿼리 문장
"현재 미국 IoT 업체와 게이트웨이 관련 특허 분쟁이 2024년에 제소된 상태이고, 이
것은 회사 내부에서도 IPO 심사 리스크로 인식하고 있습니다."
상대 문서 문장
"특허법적 분쟁 : 미국 IoT 업체와 게이트웨이 특허 분쟁 진행 중(2024년 제소), IPO
심사 리스크"
코사인 유사도: 0.89
- 쿼리 문장
"기술적으로는 센서 SoC 자체 설계 역량과 게이트웨이 모듈 특허 12건 정도 포트폴
리오가 있고, 스마트팩토리·스마트시티 쪽 수요 확대 수혜를 기대하고 있습니다."
상대 문서 문장
"O기술 경쟁력 : 센서 SoC 자체 설계, 게이트웨이 모듈 12건 특허 포트폴리오 보유"
코사인 유사도: 0.85
- 쿼리 문장
"또 일부 제품군에서 전파인증·보안인증 갱신이 지연되면서 납기 차질 사례가 이미
발생했고, 향후 규제 강화 시 연간 인증 비용 증가와 출시 지연 가능성이 큼니다."
상대 문서 문장
"보안 인증 리스크 : 일부 제품군 전파인증/보안인증 갱신 지연으로 납기 차질 발
생."
코사인 유사도: 0.83
- 쿼리 문장
"2025년 기준 매출 42억, 영업이익 5.8억 정도입니다."
상대 문서 문장
"O사업 규모 : 2025년 매출 42억 원, 영업이익 5.8억 원, 임직원 189명"
코사인 유사도: 0.83
- 쿼리 문장
"회사 자체 매출 전망은 2025년 42억에서 2030년 116억까지, 내부 기준으로는 CAGR
22.6% 시나리오를 베이스로 두고 있습니다."
상대 문서 문장
"O 매출 전망: 2025년 42억 원 → 2030년 116억 원 (CAGR 약 22.6%)"
코사인 유사도: 0.81

문서 유사도 분석 리포트

1. 개요

- 분석 대상: 쿼리 문서 1개와 상위 3개 유사 문서
- 점수 기준: BM25, 코사인 유사도, 하이브리드 점수

2. 문서 요약

- 아래 형식을 반드시 지켜주세요.
- 각 문서는 1~2문장으로 요약합니다.
- 쿼리 문서(파일명: 회의록_1): 미국 IoT 업체와 게이트웨이 관련 특허 분쟁, IPO 심사 리스크, 센서 SoC 설계 역량 및 게이트웨이 모듈 특허 포트폴리오 등을 포함한 기술 경쟁력, 2025년과 2030년의 매출 전망을 제시하고 있습니다.
- 문서1(파일명: 누누팩토리_투자보고서): 투자 여부에 대한 권고, 특허 분쟁 리스크와 보안 인증 리스크, 사업 규모 및 매출 전망, IPO 심사 리스크를 포함하고 있습니다.
- 문서2(파일명: 라움토목_투자보고서): 투자 여부, IRR과 MOIC 등의 수익성 지표, 매출

3. 상위 문서 점수 요약

순위	문서명	BM25(%)	코사인(%)	하이브리드(%)
1	누누팩토리_투자보고서	42.44	57.29	48.38
2	라움토목_투자보고서	27.26	52.12	37.20
3	시그마게임즈 투자 보고서	24.56	51.81	35.46

문서명: 누누팩토리_투자보고서

1. 쿼리 문장
- "현재 미국 IoT 업체와 게이트웨이 관련 특허 분쟁이 2024년에 제소된 상태이고, 이 건은 회사 내부에서도 IPO 심사 리스크로 인식하고 있습니다."

2	라움토목_투자보고서	27.26	52.12	37.20
3	시그마게임즈 투자 보고서	24.56	51.81	35.46

4. 유사 문장 쌍 상세

문서명: 누누팩토리_투자보고서

1. 쿼리 문장
- "현재 미국 IoT 업체와 게이트웨이 관련 특허 분쟁이 2024년에 제소된 상태이고, 이 건은 회사 내부에서도 IPO 심사 리스크로 인식하고 있습니다."
- 상대 문서 문장
- "특허법적 분쟁 : 미국 IoT 업체와 게이트웨이 특허 분쟁 진행 중(2024년 제소), IPO 심사 리스크"
- 코사인 유사도: 0.89
2. 쿼리 문장
- "기술적으로는 센서 SoC 자체 설계 역량과 게이트웨이 모듈 특허 12건 정도 포트폴리오가 있고, 스마트팩토리·스마트시티 쪽 수요 확대 수혜를 기대하고 있습니다."
- 상대 문서 문장
- "기술 경쟁력 : 센서 SoC 자체 설계, 게이트웨이 모듈 12건 특허 포트폴리오 보유"
- 코사인 유사도: 0.85
3. 쿼리 문장
- "또 일부 제품군에서 전파인증·보안인증 갱신이 지연되면서 납기 차질 사례가 이미 발생했고, 향후 규제 강화 시 연간 인증 비용 증가와 출시 지연 가능성이 큼니다."
- 상대 문서 문장
- "보안 인증 리스크 : 일부 제품군 전파인증/보안인증 갱신 지연으로 납기 차질 발생."
- 코사인 유사도: 0.83
4. 쿼리 문장
- "2025년 기준 매출 42억, 영업이익 5.8억 정도입니다."
- 상대 문서 문장
- "사업 규모 : 2025년 매출 42억 원, 영업이익 5.8억 원, 임직원 189명"
- 코사인 유사도: 0.83
5. 쿼리 문장
- "회사 자체 매출 전망은 2025년 42억에서 2030년 116억까지, 내부 기준으로는 CAGR 22.6% 시나리오를 베이스로 두고 있습니다."
- 상대 문서 문장
- "매출 전망: 2025년 42억 원 → 2030년 116억 원 (CAGR 약 22.6%)"
- 코사인 유사도: 0.81



감사합니다

